第2章 词法分析（scanner）

(1) 扫描程序（scanner）

源程序的字符 → 记号（token）

记号（token）＝自然语言如英语的单词

扫描＝拼写

例如

a[index] = 4 + 2

记号：

a 标识符

[左括号

index 标识符

] 右括号

= 赋值

4 数字

+ 加号

2 数字

如何组织输入？

输入→程序→输出

- 1.逐个符号读入，逐个符号分析
- 2.逐行读入，再逐个符号分析
- 3.整个程序读入，再逐个符号分析
- 例如：

a[index] = 4 + 2　　逐行读入

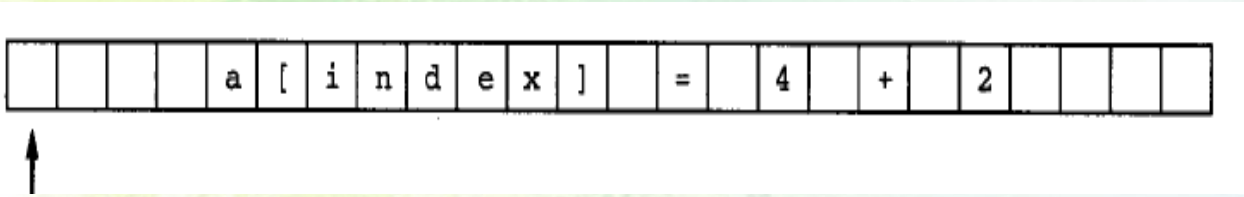

主控代码

```
switch(ch)
{
    case 字母:
    case 数字:
    case '[':
    case '=':
    case '] ':
    case '+':
    …
}
```

问题求解

- 正整数算术表达式的词法分析

问题分析

- 正整数算术表达式：
- 12+34　12-34　12*(1+3)

- 单词包含有：
- 12　34
- + - * / ( )

算法设计

问题求解-升级

- 含变量的正整数数算术表达式的词法分析

问题分析

- 正整数算术表达式：
- abc+34　12-a_b1　ab1*(var1+var2)

- 单词包含有：
- 12　34
- + - * / ( )
- 标识符abc　a_b1　ab1　var1 var2

算法设计

问题求解-升级

- 含变量的浮点数算术表达式的词法分析

问题分析

- 正整数算术表达式：
- abc+3.45　0.123-a_b1　ab1*(12.34+var2)

- 单词包含有：
- 3.45　0.123　12.34
- + - * / ( )
- 标识符 abc a_b1 ab1 var2

算法设计

问题求解-升级

- 条件判断语句的词法分析

问题分析

- 条件判断语句
- if (a>b) x=12; else y=12.34

- 单词包含有：
- 3.45 0.123 12.34
- + - * / ( ) ; = > < >= <= != ==
- 标识符 x y ab
- 保留字 if else

算法设计

字母开头的单词

```
switch(ch)
{
   case 字母:

   …
}
```

- 关键字与标识符
- 如何区分？

查找方法

- 二分查找
- 二叉排序树
- 字典树
- 散列（Hash）
- map

散列查找方法

- 散列函数
- 冲突解决方法

散列函数的构建方法

- 字母ASCII
- 字母序号

散列函数构建

- end if repeat until while ……

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26
a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	q	r	s	t	u	v	w	x	y	z

- end=5 + 14 + 4 = 23
- if=9 + 6 = 15

实验1

- C++语言的词法分析
- 1.多条件分支语句 (switch)
- 2.For 循环， while循环， do while 循环
- 3.增加八进制、十六进制数
- 4.增加注释 // /* */

- 5.还需要支持下面的单词的词法分析
- / // /* */ /= /
- < << <= <
- > >> >= >
- = == =
- * *= *
- - -- -= -> ….
- + ++ += + ….
- 0 0 0x 0X ….

问题分析

- 单词包含有：
- 3.45 0.123 12.34 3.45e+3
- + - * / ( ) ; = > < >= <= != ==
- 标识符 x y abc123 xy
- 保留字 if else do while for switch case break
- continue default
- ……

词法分析的理论

如何需要经常构造词法分析程序？

工具

自动生成工具 → 机器？

输入→自动生成工具→词法分析程序

反映单词组成的表达式

输入如何表示？

→即如何反映单词的组成形式

- 分析：算术表达式
- 10，a，a*c+b，12+23*32

正则表达式

→用数学抽象的方法来表示单词串的组成

正则表达式的缺点：

正则表达式太抽象，不利于理解，也不利于代码的编制。

→ 有穷状态机器或称有穷自动机

即正则表达式所表达单词组成的识别算法。

2.2 正则表达式

- 正则表达式表示字符串的组成。
- 正则表达式r由它所匹配的串集来定义。
- 语言L(r)——“串的集合”，
- 串的组成部分——字母表——Σ。

2.2.1 正则表达式的定义

1) 基本正则表达式

- 字母表中的单个字符且自身匹配。
- a是字母表Σ中的任一字符，则正则表达式a通过书写L(a) = {a}来匹配a字符。

- 空串就是不包含任何字符的串。
- 空串用ε(epsilon)来表示

2) 正则表达式运算

① 选择，用元字符|(竖线)表示。

- ②连结，由并置表示(不用元字符)。
- ③重复或“闭包”，由元字符*表示。

3) 选择运算

- *r*|*s*——即可匹配被*r*或*s*匹配的任意串。
- L(a|ε) ={ a, ε }。
- L(a|b|c|d) ={ a,b,c,d } 。
- a|b|...|z ——表示匹配*a*~*z*的任何小写字母。

4) 连结运算

- 正则表达式ab——只匹配*ab*,
- 正则表达式(a|b)c——则匹配串*ac*和*bc*。
- *S*1={ *aa*,*b* },*S*2={*a*,*bb* }，则
  *S*1*S*2={ *aaa*,*aabb*,*ba*,*bbb* }
- *L*((a|b)c)=*L*(a|b)*L*(c)={ *a*, *b* }{ *c* }={*ac*, *bc*}。

5) 重复——Kleene闭包(Kleene closure)

- r* ——其中*r*是一个正则表达式。
- 正则表达式r* ——匹配串的任意有穷连结，每个连结均匹配*r*。
- a*——ε 、*a*、*aa*、*aaa* ...
- (a|bb)*——ε 、*a*、*bb*、*aa*、*abb*、*bba*、*bbbb*、*aaa*、*aabb* , ...

6) 运算符优先级和括号的使用

- 正则表达式 a|b* 如何理解?
- (a|b)* ? 还是 a|(b*) ?
- 运算优先级: *优先权最高，连结其次，|最末。
- 因此，a|bc* 就可解释为a|(b(c*)),

如何组织单词对应的正则表达式

- 例1:

  一个或多个数字序列对应的一个正则表达式?

(0|1|2|...|9)(0|1|2|...|9)*

缺点:书写太长,重复量大

解决方法: 命名

digit =0|1|2|...|9

*digit digit**

- 例2.1 在仅由字母表中的3个字符组成的简单字母表$\Sigma=\{a, b, c\}$中，考虑在这个字母表上的仅包括一个b的所有串的集合

- 解答：即b的两边可以有任意多个其它符号

(a|c)*b(a|c)*

- 例2.2 在与上面相同的字母表中，如果集合是包括了最多一个*b*的所有串，

- 解答:
- （1）可理解为没有b或只有一个b.

  (a|c)*|(a|c)*b(a|c)*

- （2）也可理解为：允许*b*又允许空串在重复的*a*或*c*之间出现，于是有另一个解：

  (a|c)*(b|ε)(a|c)*

- 注意：不同的正则表达式可生成相同的语言。

- 例2.3 在字母表Σ={a,b}上的串S的集合是由一个b及在其前后有相同数目的a组成：

- $S = \{ b, aba, aabaa, aaabaaa, \ldots\} = \{ a^n b a^n \mid n >=0 \}$

- 正则表达式并不能描述这个集合

• 标识符的正则表达式

- 标识符必须由一个字母开头且只包含字母和数字。
- 正则表达式为：

$$letter = a\ |b|...z|A|B|...Z$$

$$digit = 0|1|2|...|9$$

$$identifier = letter(letter|\ digit)^*$$

缺点:书写繁琐,是否可以简化

• 整数的正则表达式

- 整数可以正整数（可带正号或不带）、负整数。

- digit= 0|1|2|...|9
- *natural*=digit digit*
- signedNatural=natural|+natural|-natural

缺点:重复量大,是否可以简化

• 正则表达式的简化

- 缺点:书写繁琐
- →导致这个问题的核心是什么?
- 提供的运算太少了→扩充运算符号

1.正闭包:一个或多个重复

- r^*表示允许r被重复0次或更多次。
- r^+表明r的一个或多个重复。
- 如: (0|1)(0|1)*　　简化:　　$(0|1)^+$
- 如:natural=digit digit*

  简化: natural=$digit^+$

2.字符范围表示运算符

- a | b|...|z 来表示小写字母
- 0|1|...|9来表示数字　　复杂
- 用连字符——[a-z]是指所有小写字母，[0-9]则指数字。
- a|b|c可写成[abc]
- [a-zA-Z]代表所有的大小写字母。

3.表示可选的运算符

- 例如，整数的正则表达式为

  natural=[0-9]+

  signedNatural=*natural*|+*natural*|-*natural*　　复杂

- 引入元字符？
- r?——表示由*r*匹配的串是可选的
- 整数则可简化为：

  natural=[0-9]+

  signedNatural=(+|-)?*natural*

4.表示任意字符的运算符

- 句号“.”表示任意字符匹配的典型元字符

- 至少有一个*b*的串对应正则表达式为：

.*b.*

5. 不在给定集合中的任意字符

- “～”，那么表示字母表中非a字符的正则表达式就是~a。

- 非a、b及c表示为：

  ~(a|b|c)

• 十进制数的正则表达式

- 十进制数可以是整数、浮点数、或带有指数的数(由e或E表示)的序列。
- 如：123　3.14　-4.5　2.71E-2
- 正则式：

nat=[0-9]+

signedNat=(+|-)?nat

number=signedNat("."nat)?(E signedNat)?

• 注释的正则表达式

- 注释可有若干个不同的格式。
- 例如：

```
{ this is a Pascal comment }
/* this is a C comment */
```

- 或行注解，如：

```
; this is a Scheme comment
-- this is an Ada comment
```

单个分隔符的注释

如pascal注解：{ this is a Pascal comment }

正则表达式：　　{ (~})* }

两个分隔符的注释

C语言的注解：/* this is a C comment */

- /*...(*/不同时出现的任意长度串)...*/
- /* (~(*/))* */ 错
- 缺陷：正则表达式表达能力不强

• 二义性问题

- 例如：
- <= → 两种理解：

  （小于号、等号）和 小于等于号

- 解决方法：
- 最长子串原理(principle of longest substring)

C++单词的二义性

- / // /* */ /= /
- < << <= <
- > >> >= >
- = == =
- * *= *
- - - -= -- -> ….
- + ++ += + ….
- 0 0 0x 0X ….
- ……

正则表达式的缺点

正则表达式太抽象，不利于理解，也不利于代码的编制。

→ 有穷状态机器或称有穷自动机

即正则表达式所表达单词组成的识别算法。

- 2.3 有穷自动机

- ——有穷状态的机器
- ——是描述(或“机器”)特定类型算法的数学方法。
- ——可用作描述在输入串中识别模式的过程
- ——可用作构造扫描程序。

- 有穷自动机与正则表达式之间关系？

- 例：identifier=letter(letter|digit)*　有穷自动机？

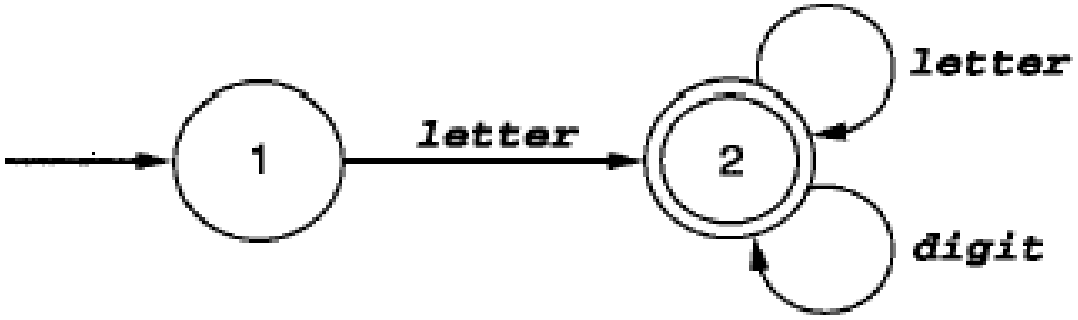

- 状态(state)
- 初始状态（start state）
- 接受状态(accepting state)
- 转换 (transition)
- 识别过程：

如xtemp：

→1→2→2→2→2→2

- 方便地展示出算法过程，因此它对于有穷自动机的描述很有用处。

- 等价图

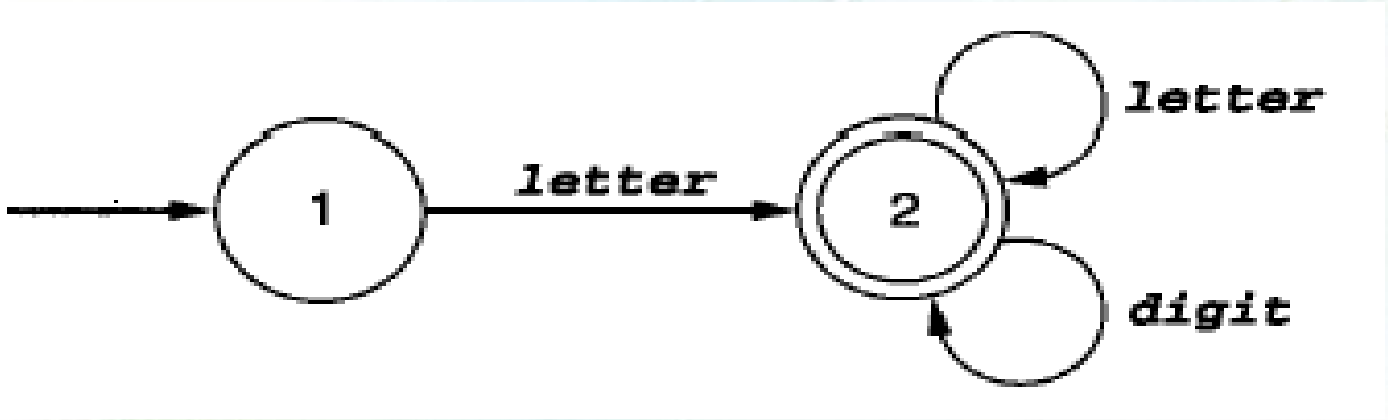

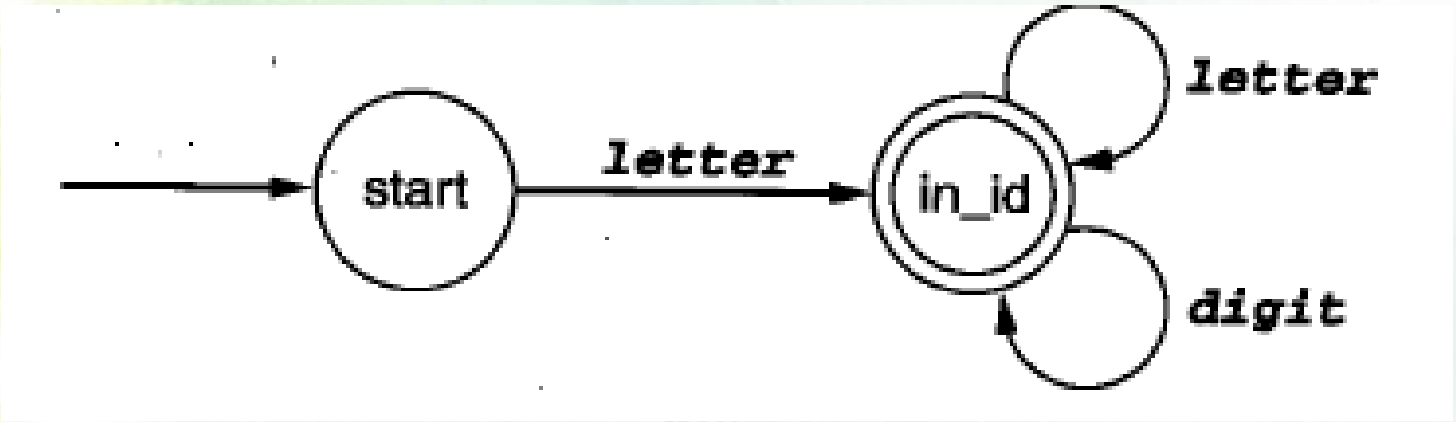

DFA图的疑惑

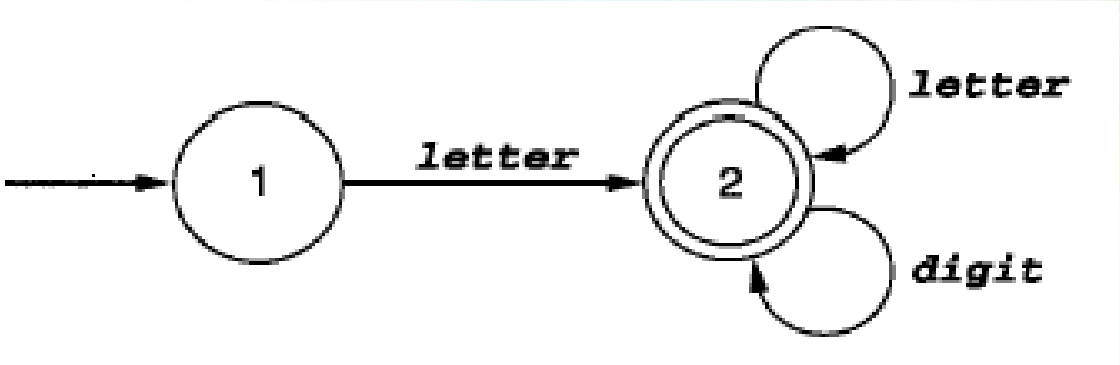

- 输入为： 1xtemp

- 出错转换(error transition)

——没画而假设它总是存在

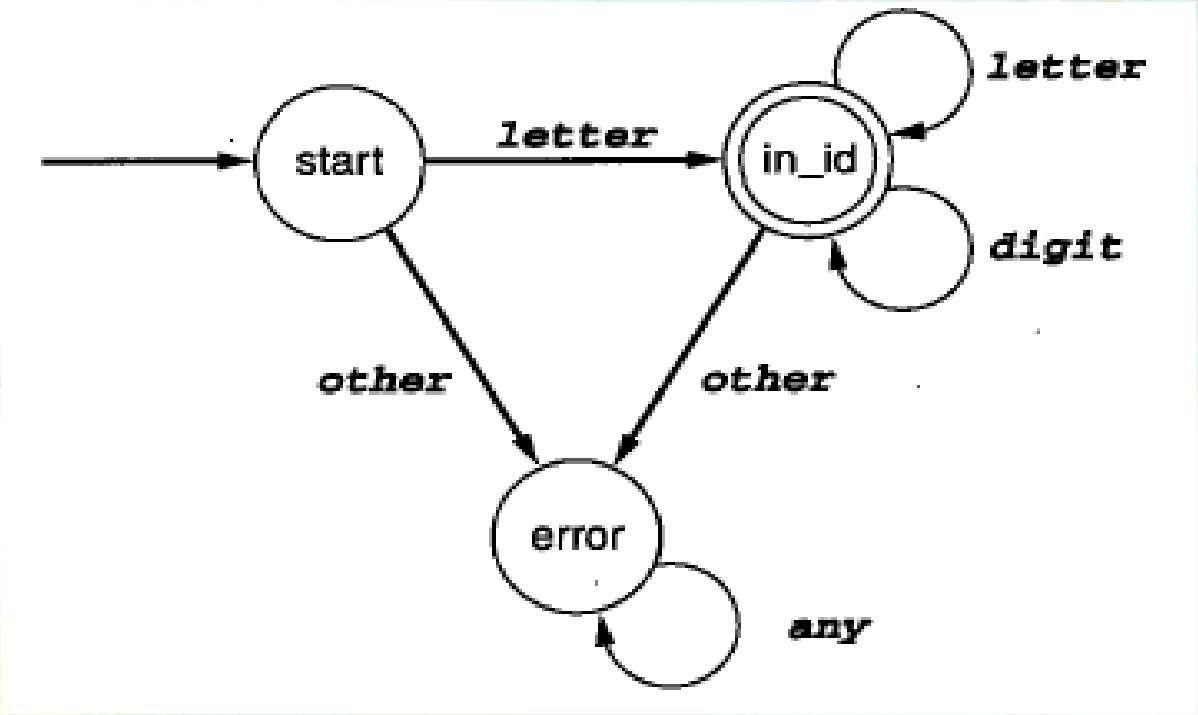

又有新的疑惑:

如果输入的串为 xtemp=1; 则.....

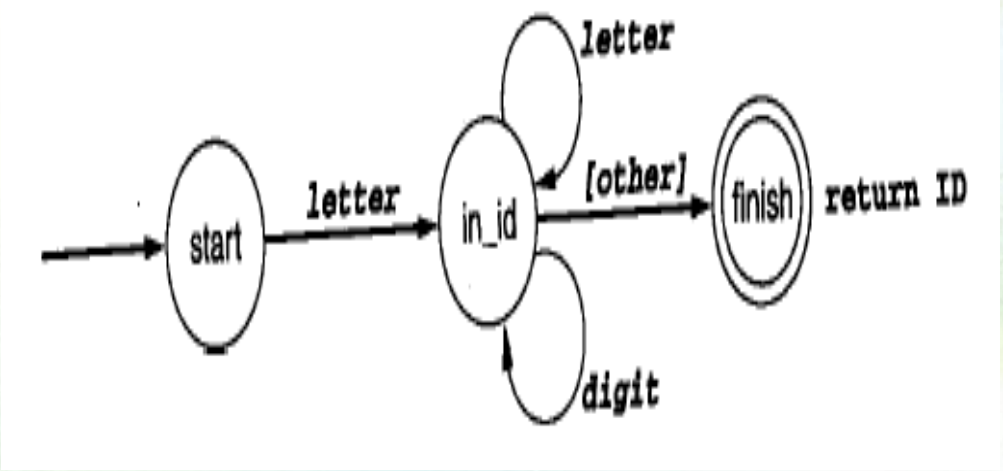

- 解决方法：带有方括号，表示应先行考虑分隔字符，也就是：应先将其返回到输入串并且不能丢掉。

- ——最长子串原理

- 2.3.1 确定性有穷自动机的定义——DFA

- 即：下一个状态由当前状态和当前输入字符唯一给出的自动机。

- 定义：DFA M由字母表Σ、状态集合S、转换函数T：$S\times\Sigma\rightarrow S$、初始状态$s_0\in S$及接受状态集合$A\subset S$组成。

- 正则表达式与DFA之间的关系

- 相互转换
- 例1:正则表达式 ab
- 例2:正则表达式 a|b
- 例3:正则表达式 a*
- 例4:正则表达式 (ab)*
- 例5:正则表达式 (a|b)*
- 例6:正则表达式 ab|ac

- 例2.6: 串中仅有一个*b*的集合的正则表达式为：

  (not b)* b (not b) *

- 其对应的DFA为：

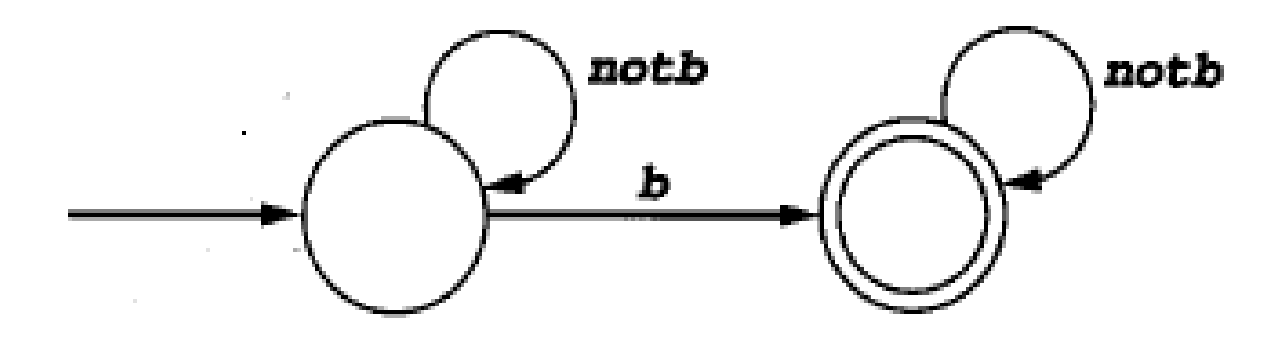

- 例2.9 非嵌套注释的DFA描述。
- 例如，Pascal注释{ (~}) * }对应的DFA为：

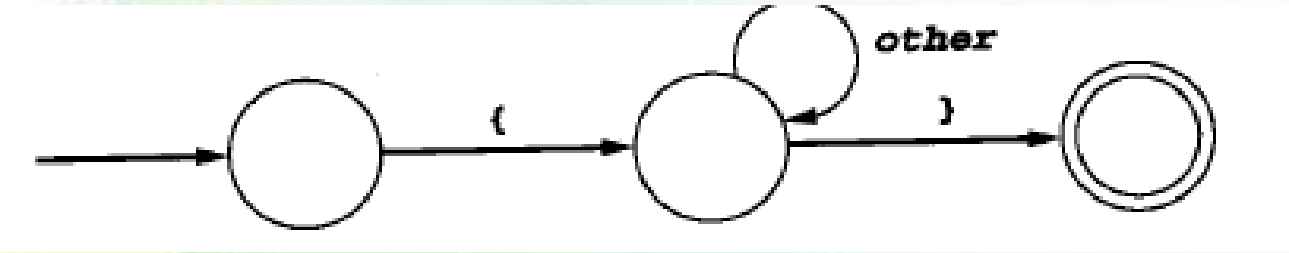

- 注意：other意味着除了右边花括号外的所有字符。

- C注释 —— 正则表达式困难！！

/* ...(*/不同时出现)... */

- DFA表示则非常简单：

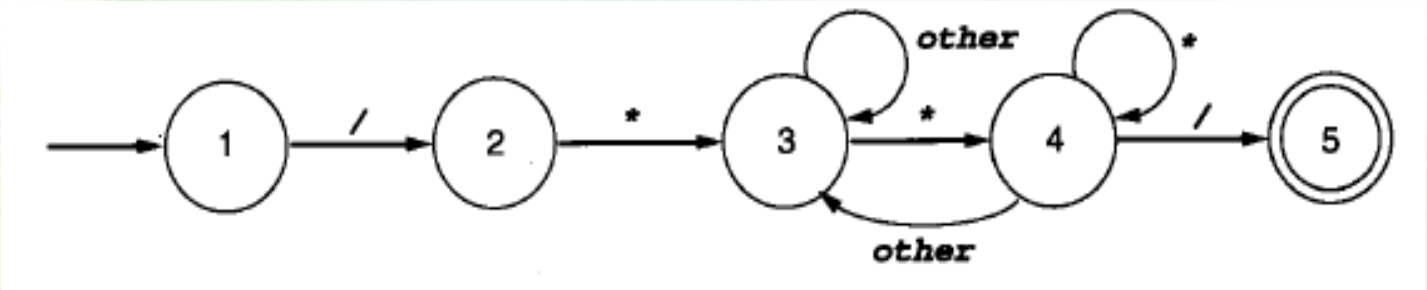

- 结论：DFA的表达能力比正则表达式强！！

- 例2.8 科学表示法的数字常量的正则表达式为：

  nat=[0-9]+
  signedNat=(+|-)?*nat*
  number=*signedNat*("."*nat*)?(E *signedNat*)?

- 如何画对应的DFA?　　分解

- 第一步：引入名字进行简化

  digit=[0-9]
  nat=*digit*+
  signedNat=(+|-)? *Nat*
  number=*signedNat*("."*nat*)?(E *signedNat*)?

- 第二步：画出nat 的DFA：

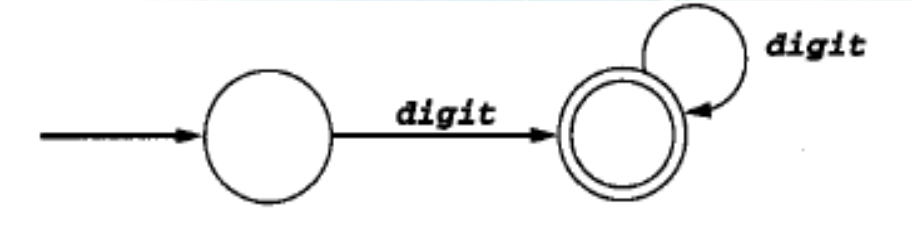

- 注意：请记住a+=aa*对任意的a均成立。

- 第三步：画出signedNat=(+|-)? Nat 的 DFA：
  - 添加可选的+|-

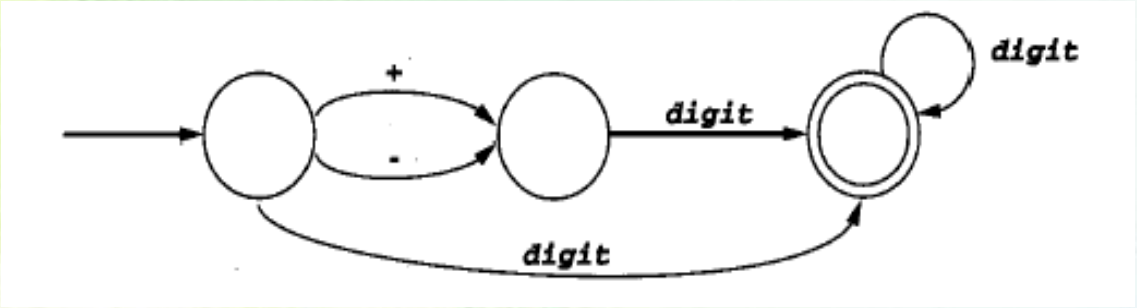

- 第四步:画出signedNat(“.” Nat) 的DFA：
  - 添加小数部分

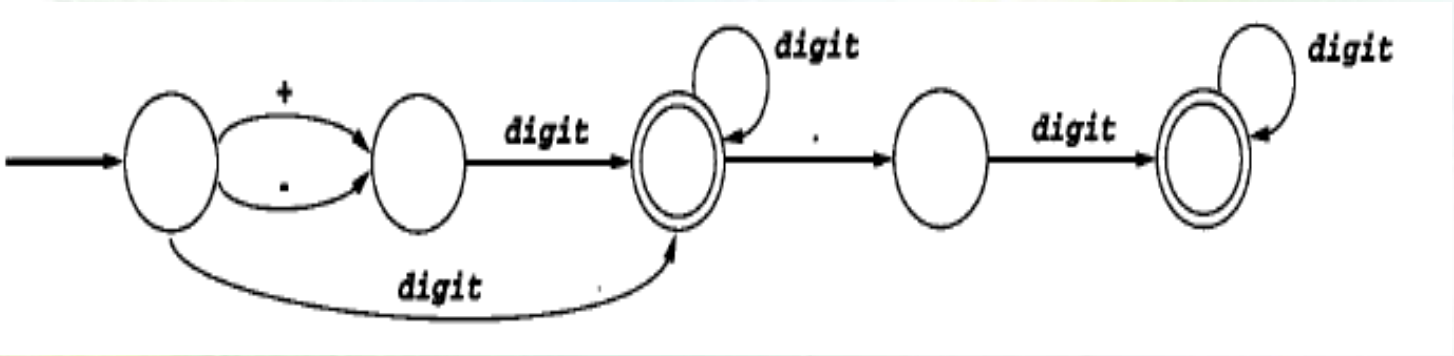

- 注意：它有两个接受状态，它们表示小数部分是可选的。

第五步：*signedNat*(“.” *nat*)?(E *signedNat*)?的DFA

- 添加可选的指数部分

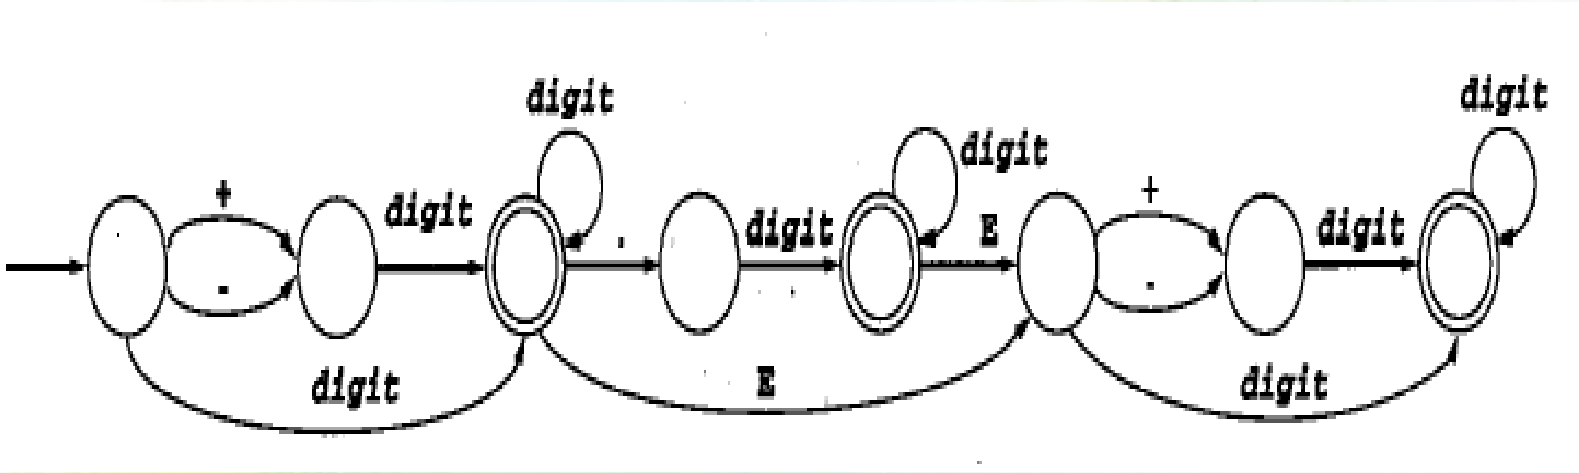

- 结论：直接将正则表达式转换为DFA不容易，规律不容易找！！ 怎么办？？

转换困难的原因分析

- 状态身份重叠

  → 粘合不容易

- 状态身份的分析

- 正则表达式与DFA之间的关系

- 相互转换
- 例1:正则表达式 ab
- 例2:正则表达式 a|b
- 例3:正则表达式 a*
- 例4:正则表达式 (ab)*
- 例5:正则表达式 (a|b)*
- 例6:正则表达式 ab|ac

- 例2.8 科学表示法的数字常量的正则表达式为：

  nat=[0-9]+

  signedNat=(+|-)?*nat*

  number=*signedNat*("."*nat*)?(E *signedNat*)?

转换困难的原因分析

- 状态身份重叠

  → 粘合不容易

- 状态身份的分析

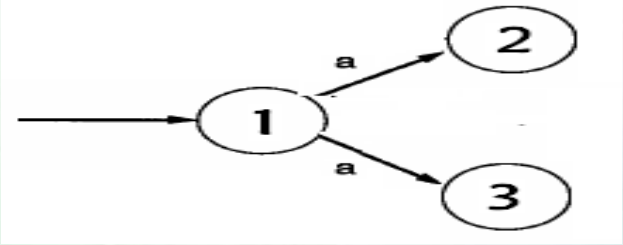

- （1）允许一对多的转换
- （2）允许ε-转换

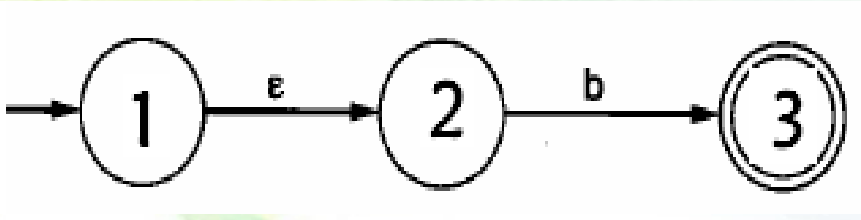

- 引入新的有穷自动机

- 非确定性有穷自动机
  (nondeterministic finite automaton)

- 简称为NFA。

- NFA与DFA不同之处：

- （1）允许ε-转换

- （2）允许一对多的转换

NFA(nondeterministic finite automaton)

- 定义：NFA M由字母表Σ、状态的集合S、转换函数T: S×(Σ∪{ε})→ ℘(S)、S的初始状态s0，以及S的接受状态A的集合组成。

例.观察下面的NFA图是否能接受串abb：

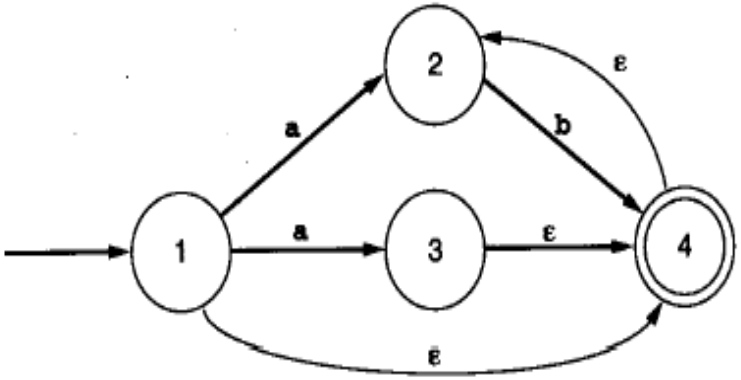

$\rightarrow 1 \xrightarrow{a} 2 \xrightarrow{b} 4 \xrightarrow{\varepsilon} 2 \xrightarrow{b} 4$

$\rightarrow 1 \xrightarrow{a} 3 \xrightarrow{\varepsilon} 4 \xrightarrow{\varepsilon} 2 \xrightarrow{b} 4 \xrightarrow{\varepsilon} 2 \xrightarrow{b} 4$

分析该NFA所对应的正则表达式：

（1） 1→2→4等得： ab+

（2） 1→3→4等得： ab*

（3） 1→4等得： b*

因此，这个NFA与正则表达式$ab^+|ab^*|b^*$相同表达。

即$ab^+|ab^*|b^* \Rightarrow ab^*|b^* \Rightarrow (a|\varepsilon)b^*$

(a|ε)b* 对应的DFA为：

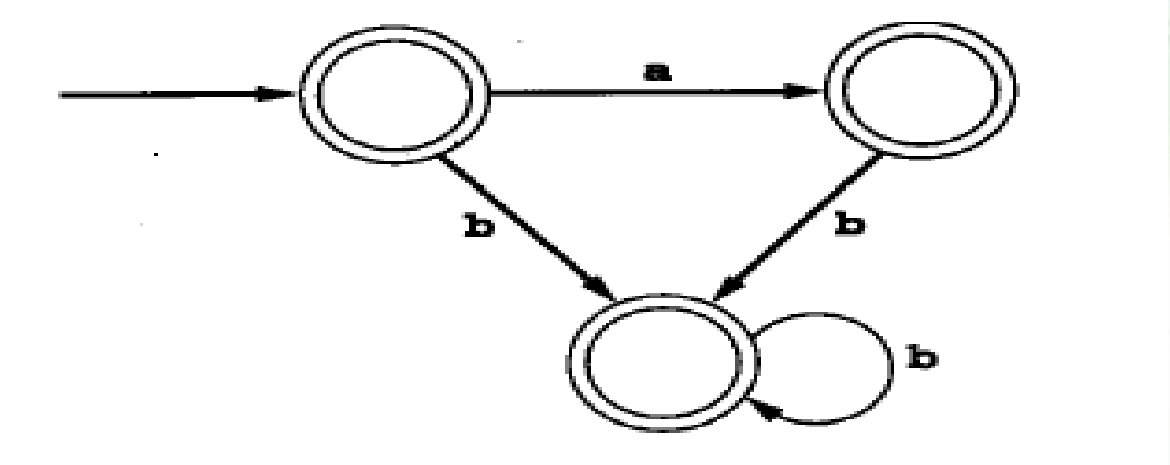

思考：是否有其他的NFA也可接受这个语言？

2.4 正则表达式→DFA

- 方法1: 直接转换 → 困难，复杂,难以找到规律
- 方法2：引入中间模型 →NFA → 简单，有规律

- 方法2的介绍

- (1)将正则表达式→NFA

- (2)将NFA→DFA

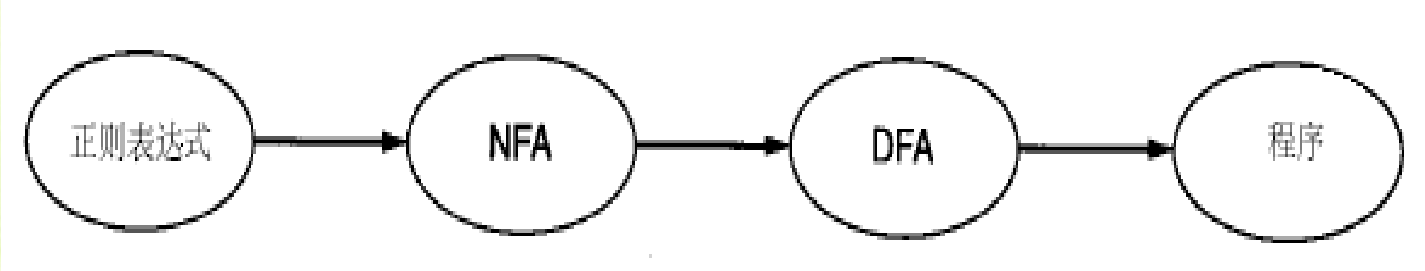

2.4.1 正则表达式 → NFA

- Thompson方法(Thompson construction)
- Thompson方法利用ε-转换将正则表达式的机器片段“粘在一起”以构成与整个表达式相对应的机器。
- 归纳方法 → 即从正则表达式定义出发，
  - 首先为每个基本正则表达式画出一个NFA，
  - 接着根据正则表达式的运算符号特点将各个NFA连接起来。

如何掌握好该转换方法

- （1）弄清楚一个基本正则表达式对应的NFA是如何画出来的。

- （2）弄清楚各种运算符号在NFA图中的连接方法。

  或运算 |

  并置运算

  重复运算 *

- 1) 基本正则表达式

- 与正则表达式a等同的NFA:

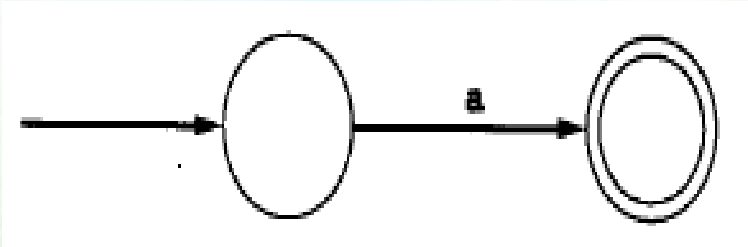

- 与ε等同的NFA：

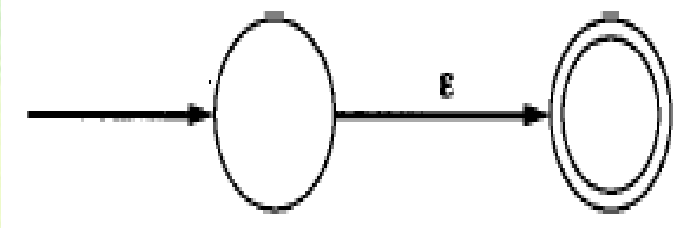

2) 并置

与 r s 对应的NFA：

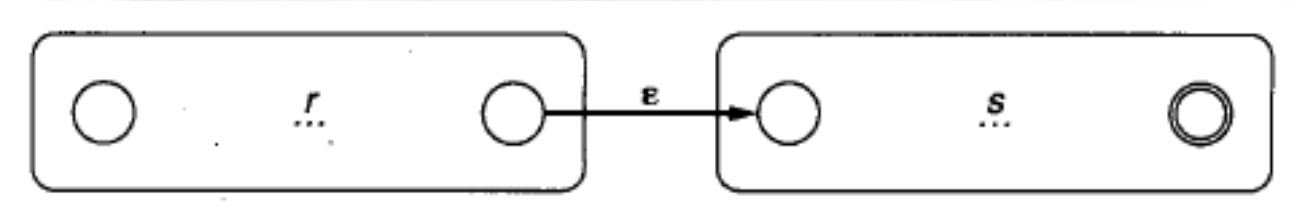

- 3) 在各选项中选择

与$r|s$相对应的NFA：

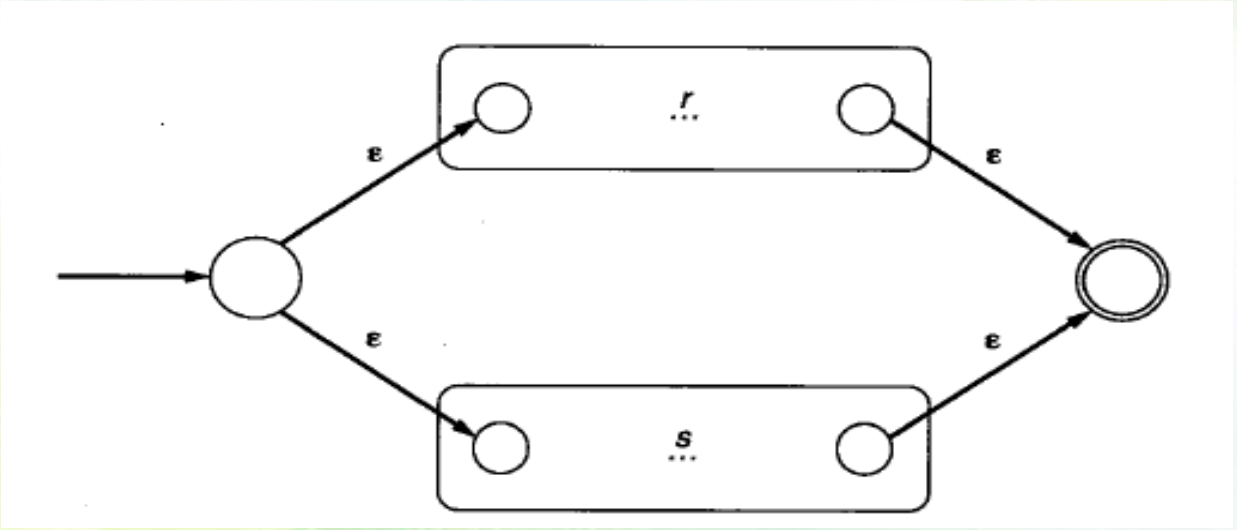

- 4) 重复

- r*相对应的NFA：

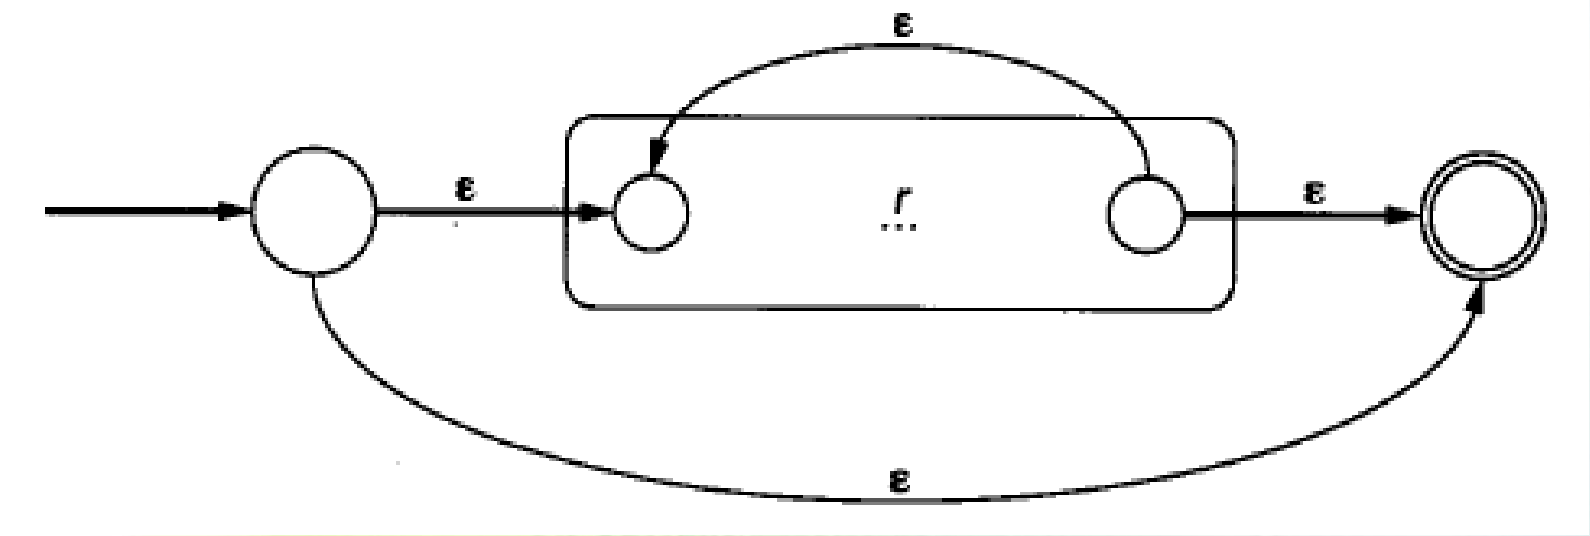

- 例1 将正则表达式ab|a转换为NFA。

- 首先为正则表达式a和b分别构造机器：

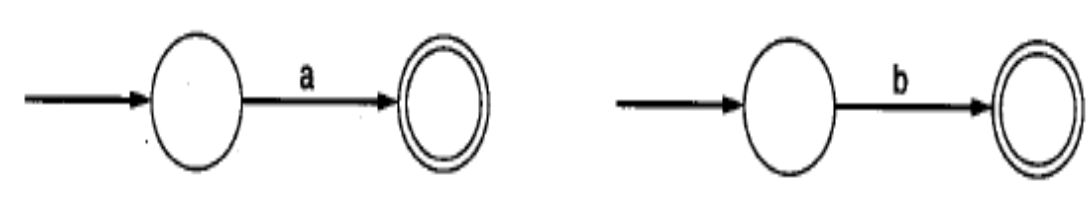

- 接着再为并置ab构造机器：

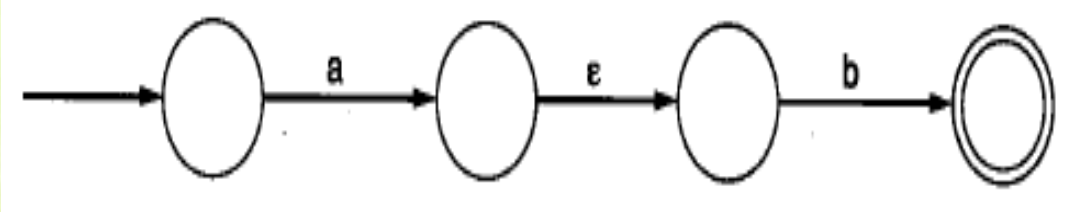

- ab|a 对应的NFA：

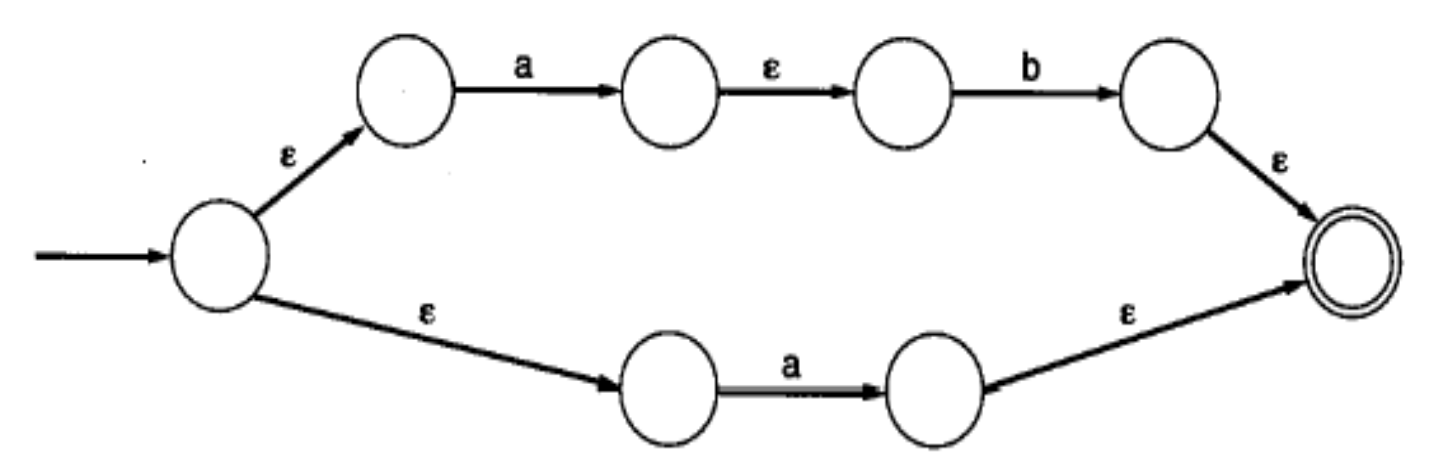

- 例2 正则表达式 *letter*(*letter*|*digit*)*对应的NFA。

- 首先分别为正则表达式*letter*和*digit*构建机器：

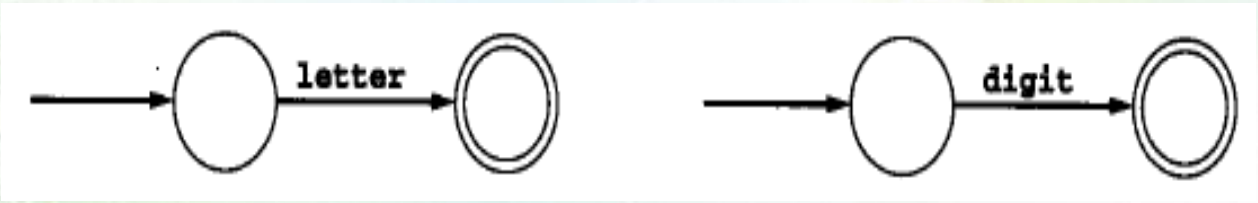

- 接着再为选择*letter*|*digit*构造机器：

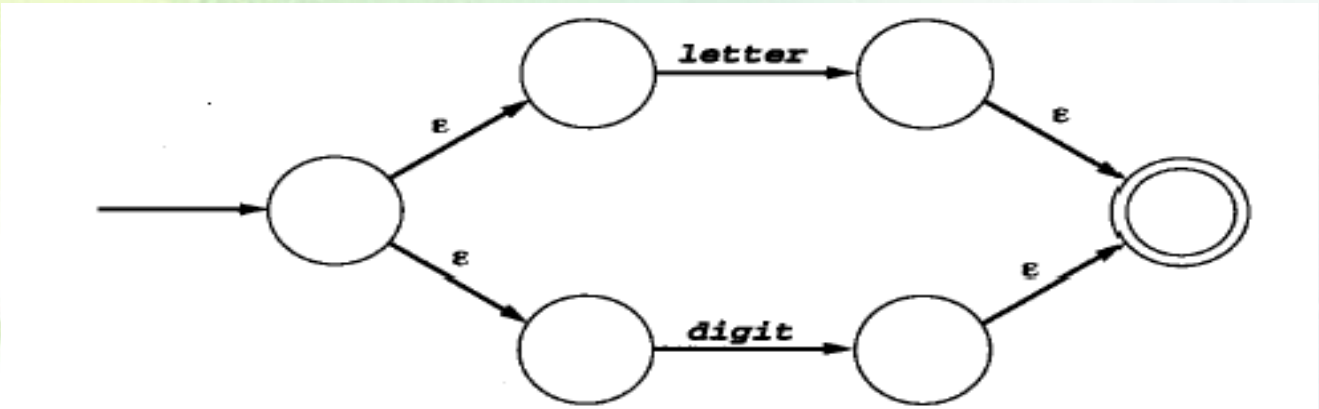

- 重复(*letter*|*digit*)*构造NFA，如下所示：
-

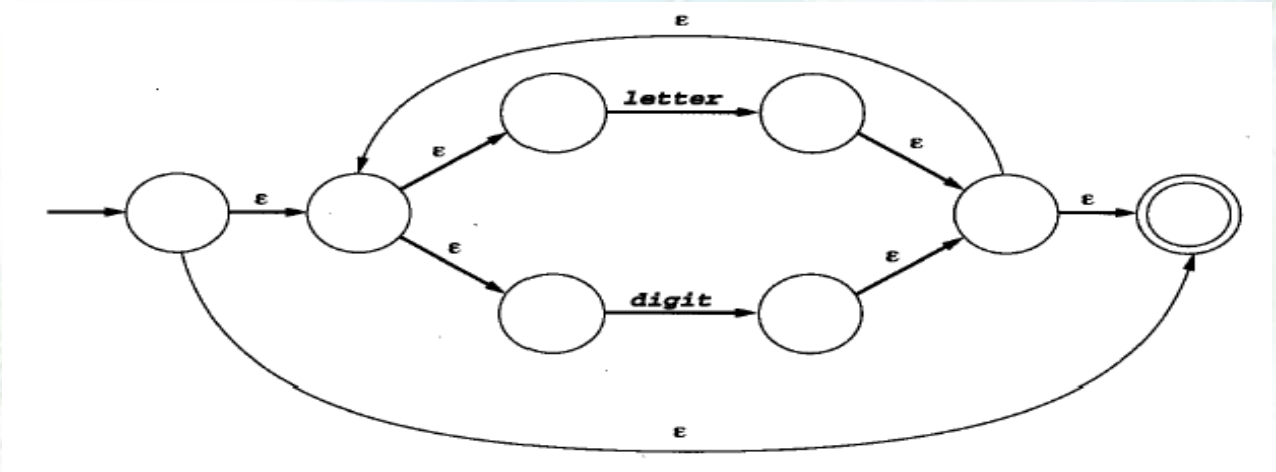

- 最后，将*letter*和(*letter*|*digit*)*并置在一起，并构造该并置的机器以得到完整的NFA：

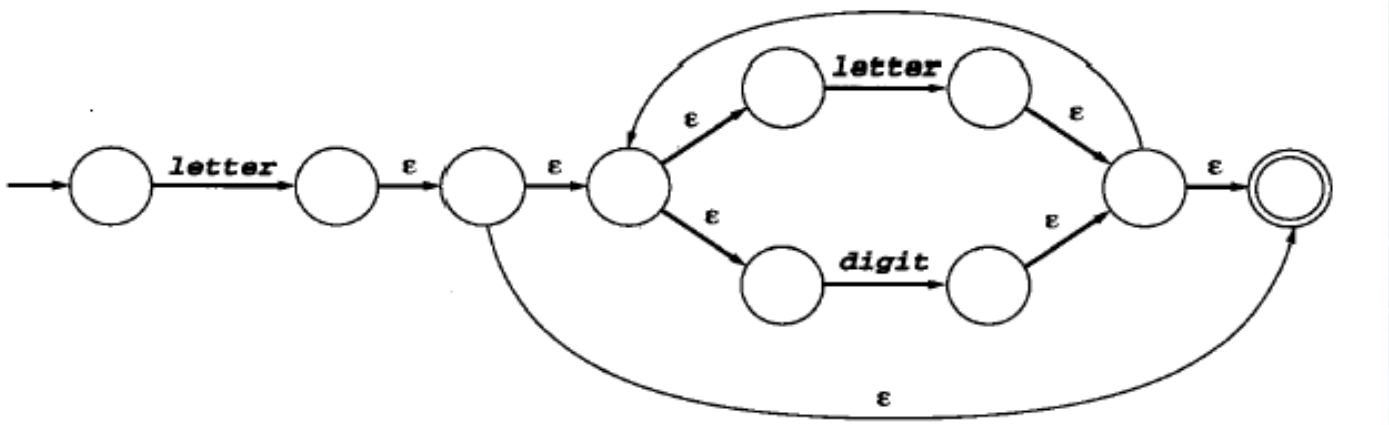

- 例：正则表达式(a|c)*b按Thompson方法构造所得NFA如图：

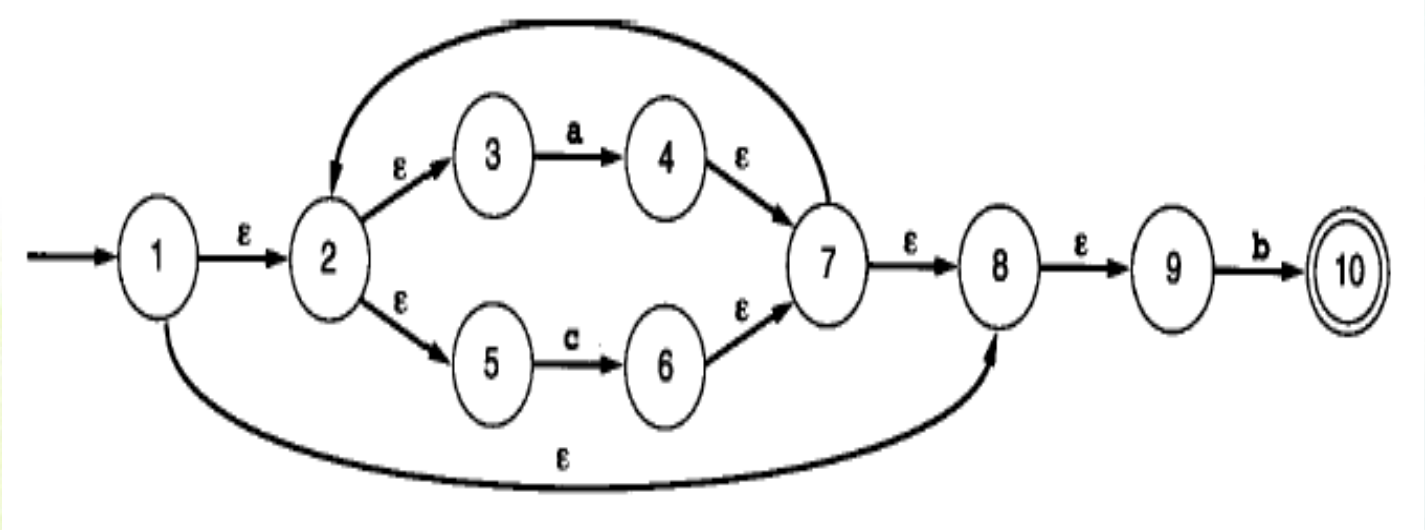

2.4.2 NFA → DFA

- 合并等价状态
- 分析NFA与DFA有何不同：
- （1）ε- 转换
- （2）多重转换

- (1)消除ε-转换

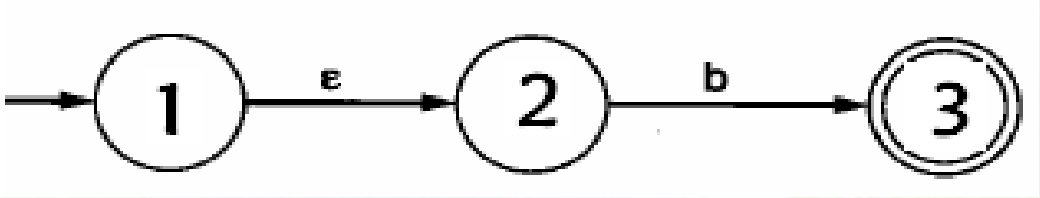

由于ε是空串，因此，可以1,2状态理解为一样

ε- 闭包(ε-closure)是可由ε-转换从某状态或某些状态达到的所有状态集合。

即状态1的ε- 闭包(ε-closure)为：{1，2}

- (2)消除多重转换

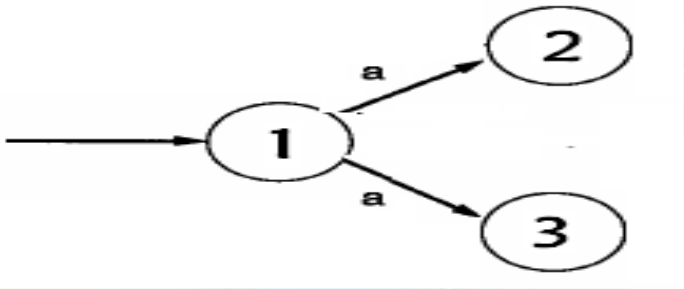

- 即 F(1,a)={2,3}

- **结论**：因为这两个过程得到的结果均是状态集合而不是单个状态，因此称这个算法为**子集构造**(subset construction)。

如何实现转换

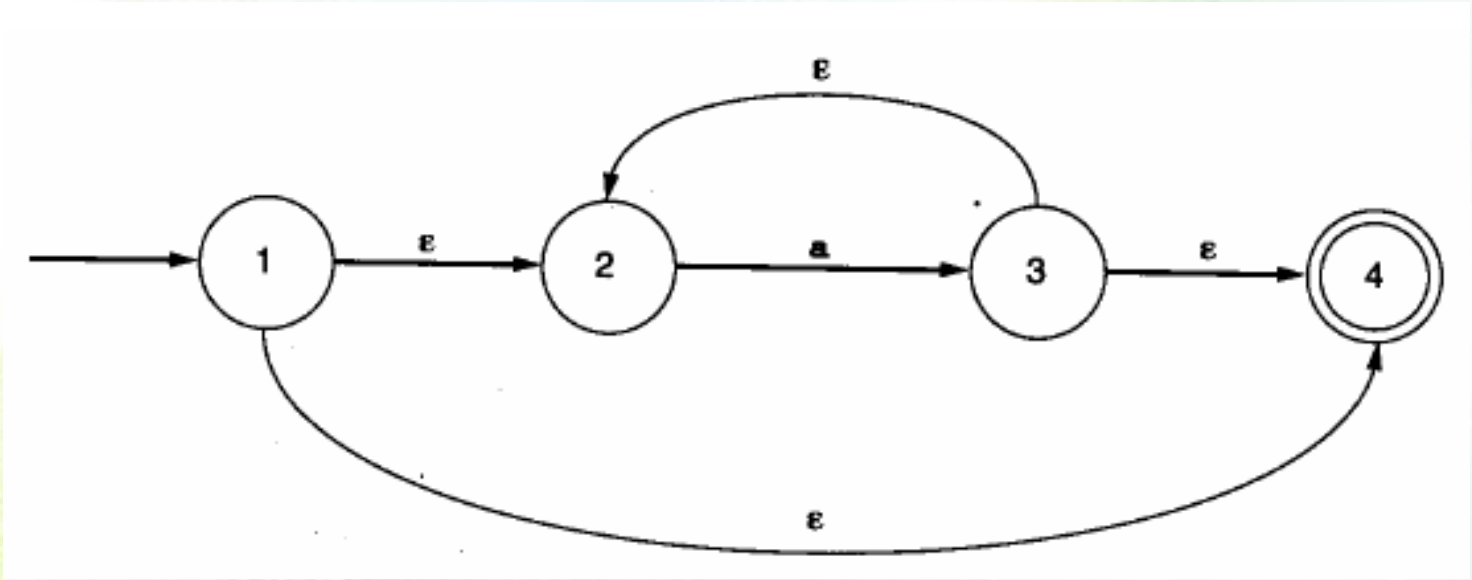

如何实现转换

- 从目标出发找出解决方法：

- 1.DFA初态只有一个。

  →意味着要把NFA中的初态进行等价合并。

- 2.DFA中存在的都是非ε转换。

  →意味着从初态开始进行非ε转换，如果得到新状态就要进行新一轮的处理。

例1 求出正则表达式a*对应NFA初态1的等价状态：

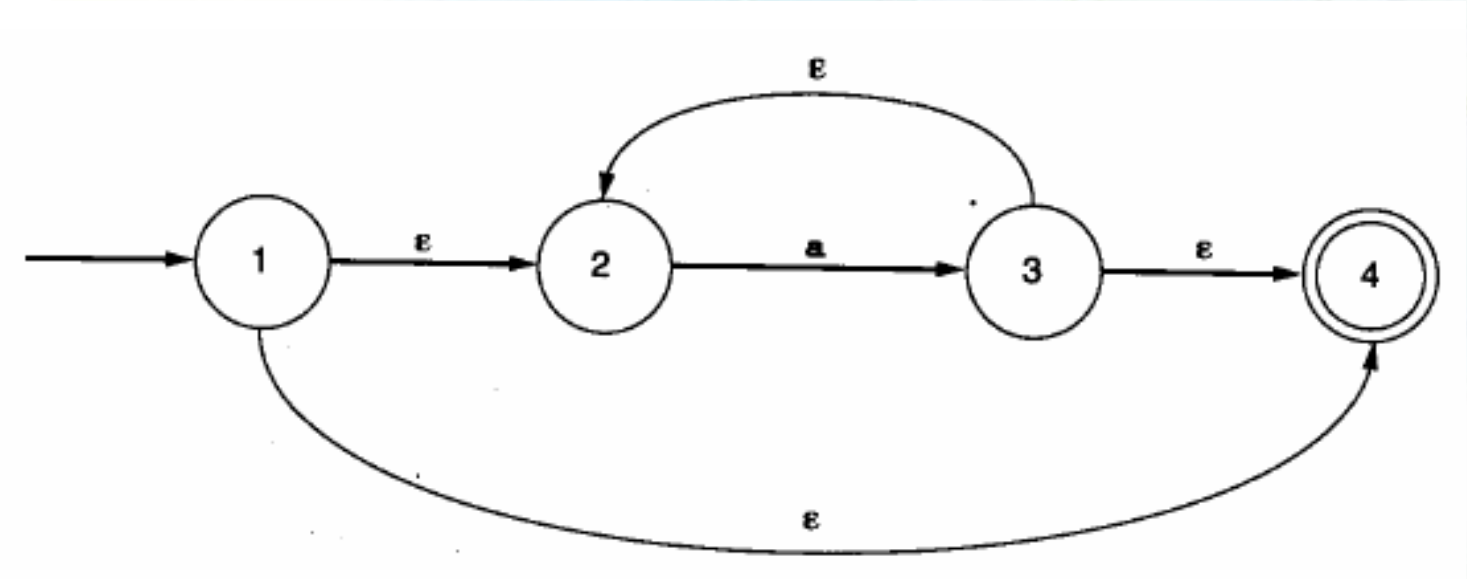

初态1的等价状态有:{1, 2, 4},书写为： $\overline{1} = \{1,2,4\}$

$\overline{s}$ 称为状态s的ε-闭包：即由一系列的零个或多个ε-转换所能达到的状态集合。

例：求初态集合{1,2,4}的非ε转换。

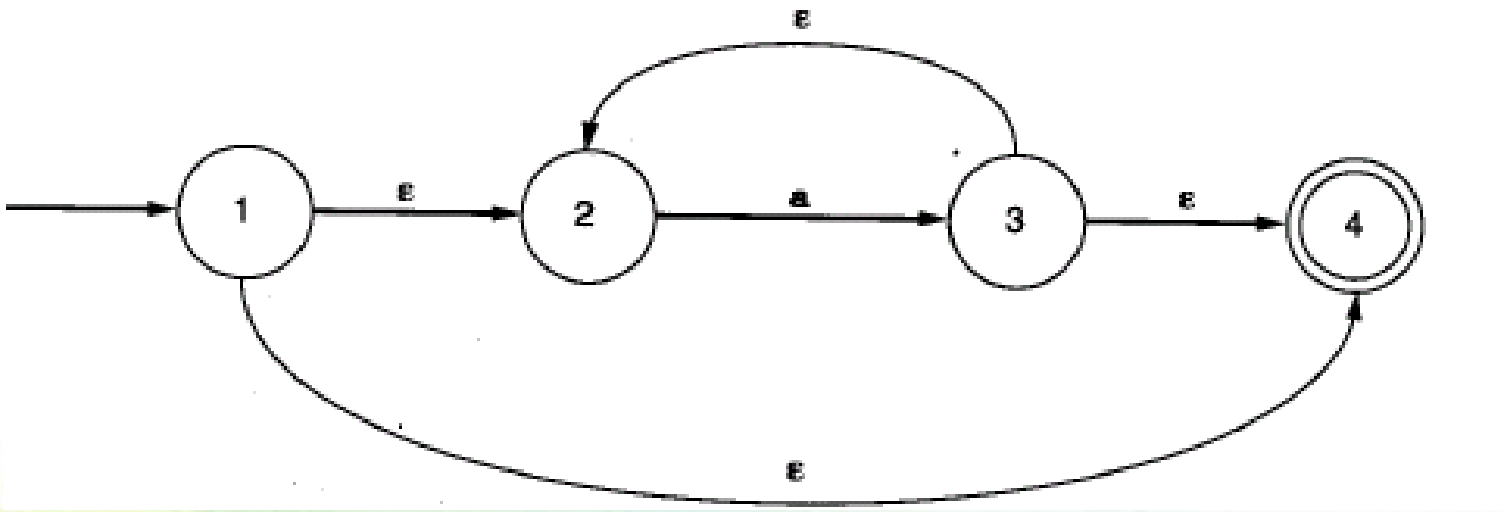

NFA初始状态1的ε-闭包={1,2,4}，而转换只有a上的转换.

例2.15　请考虑例2.14中的NFA：与它相对应的DFA的初始状态是 $\overline{1} = \{1,2,4\}$，且存在着在字符a 上的由状态2向状态3的转换，而在a 上则没有来自状态1或状态4的转换，因此在a 上就有从$\{1,2,4\}$到 $\overline{\{1,2,4\}}_a = \overline{\{3\}} = \{2,3,4\}$ 的转换。由于再也没有来自一个字符上的1、2或4状态的转换了，因此就可将注意力转向新状态$\{2,3,4\}$。此时在a 上有从状态2到状态3的转换，且也没有来自3或4状态的a- 转换，因此就有从$\{2,3,4\}$到 $\overline{\{2,3,4\}}_a = \overline{\{3\}} = \{2,3,4\}$ 的转换，因而也就有从$\{2,3,4\}$到它本身的a- 转换。我们已将所有的状态都考虑完了，所以也构造出了整个DFA。唯一需要读者注意的是NFA的状态4是接受的，这是因为$\{1,2,4\}$和$\{2,3,4\}$都包含了状态4，它们都是相应的DFA的接受状态。将构造出的DFA画出来，其中用状态各自的子集命名状态：

于是转换得到的DFA为：

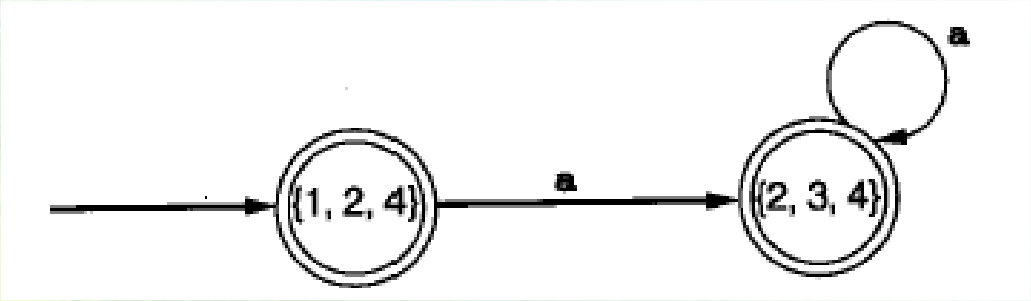

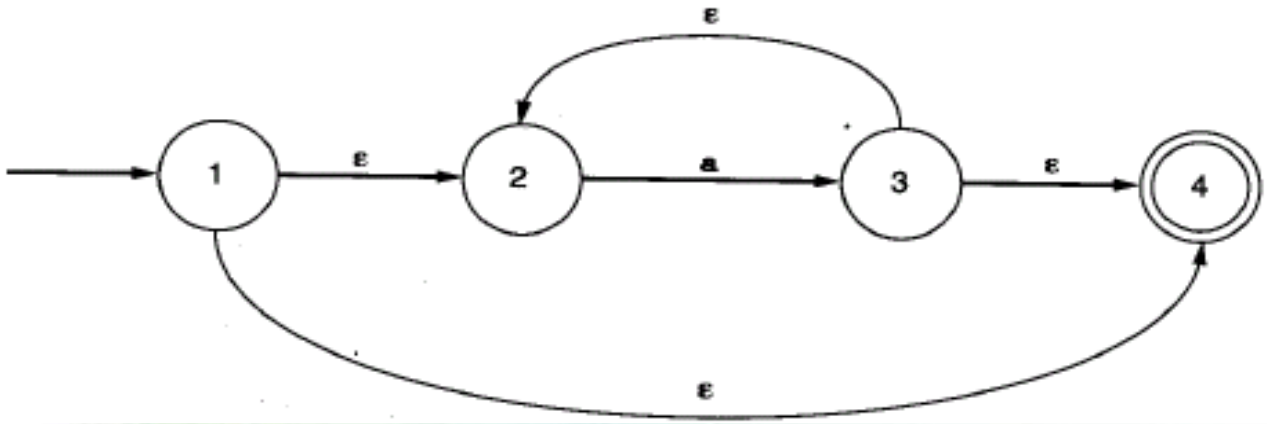

字符 / 状态集合	a
{1, 2, 4}	{2, 3, 4}
{2, 3, 4}	{2, 3, 4}

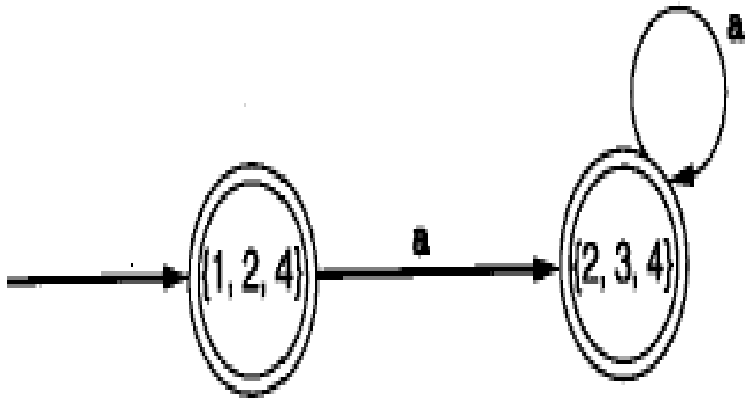

- 例2 将下面NFA转换为DFA.

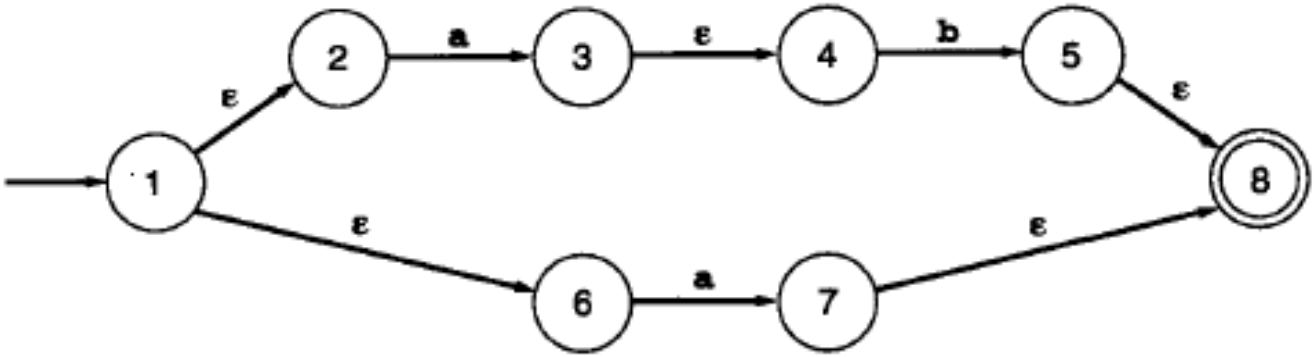

则子集构造过程用下表表示：

字符 / 状态集合	a	b
{1,2,6}	{3,4,7,8}	
{3,4,7,8}		{5, 8}
{5, 8}		

因此所得的DFA为：

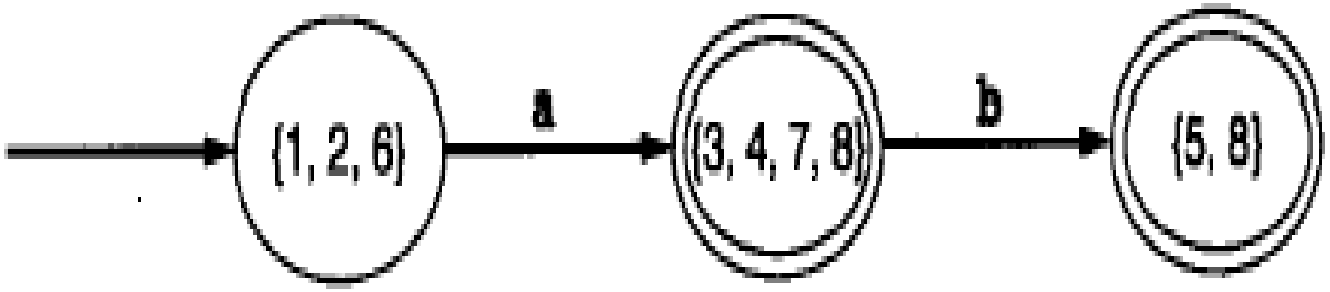

- 例3.将下面NFA转换为DFA。

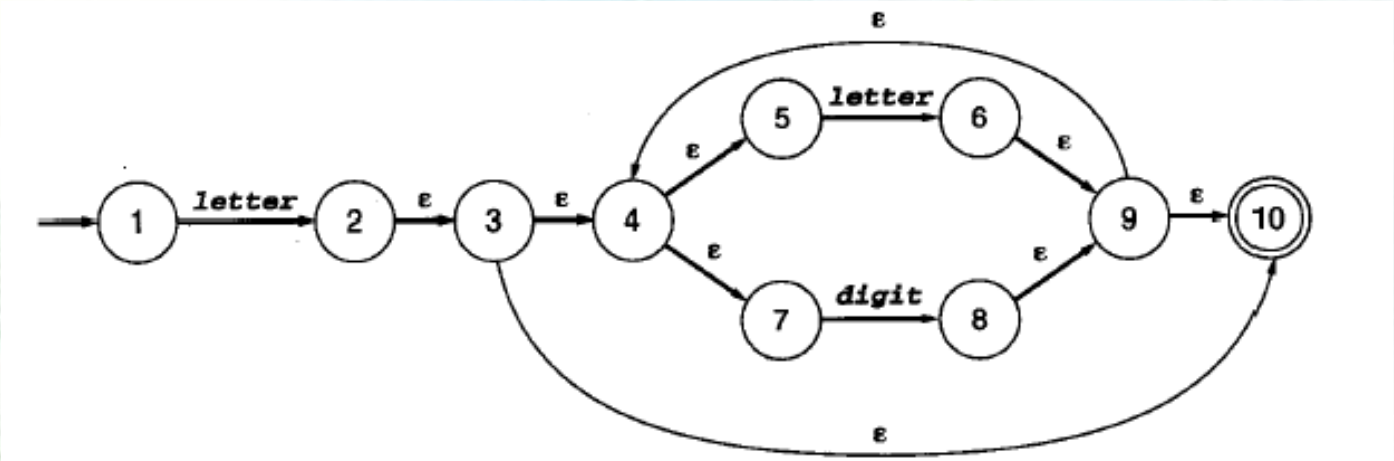

- 子集构造过程用下表表示：

字符 / 状态集合	letter	digit
{ 1 }	{ 2,3,4,5,7,10 }	
{ 2,3,4,5,7,10 }	{ 6,9,4,7,10,5 }	{ 8,9,4,7,5,10 }
{ 6,9,4,7,10,5 }	{ 6,9,4,7,10,5 }	{ 8,9,4,7,5,10 }
{ 8,9,4,7,5,10 }	{ 6,9,4,7,10,5 }	{ 8,9,4,7,5,10 }

因此，得到的DFA如下图：

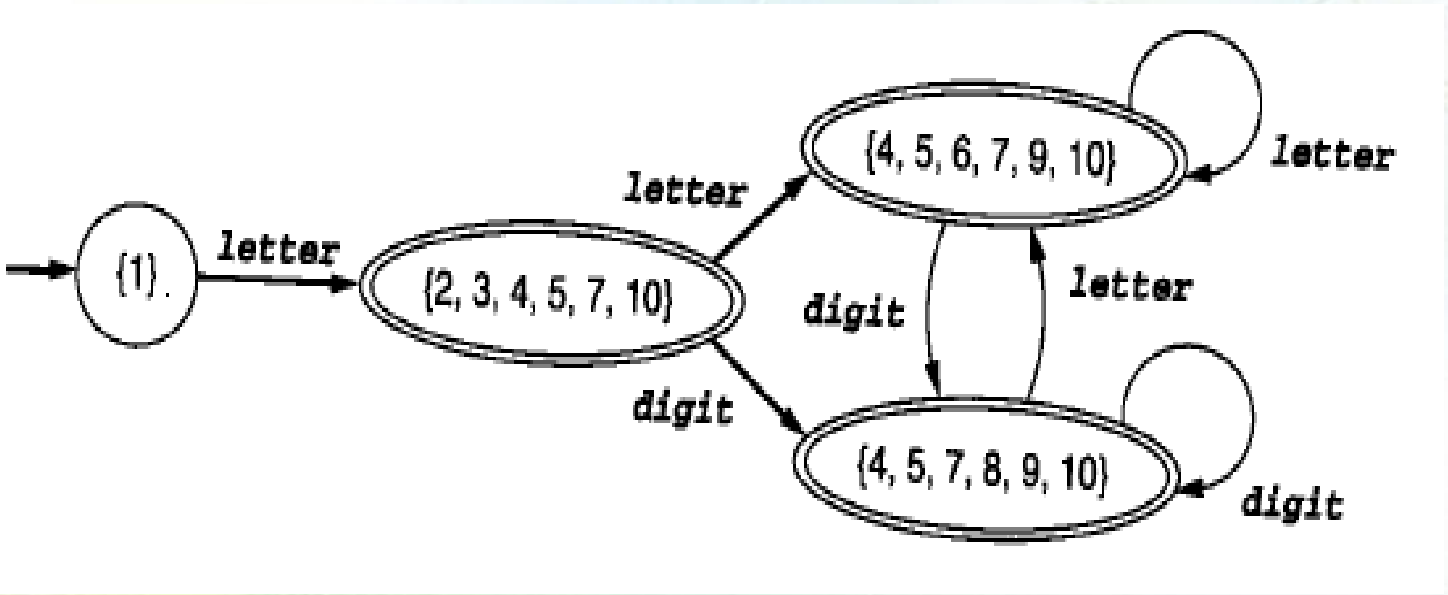

缺陷：转换得到的DFA太复杂，状态数太多。

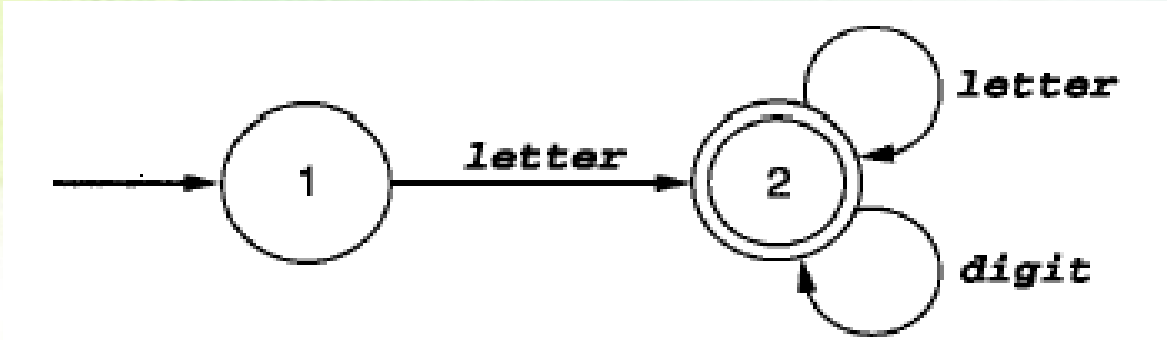

如何最小化——方法一

- 状态数最少

  →即意味着把多余的、等价的状态进行合并

  →等价：目标一致即可

- 如何进行等价合并呢？

  →逐个状态逐个状态进行分析比较。

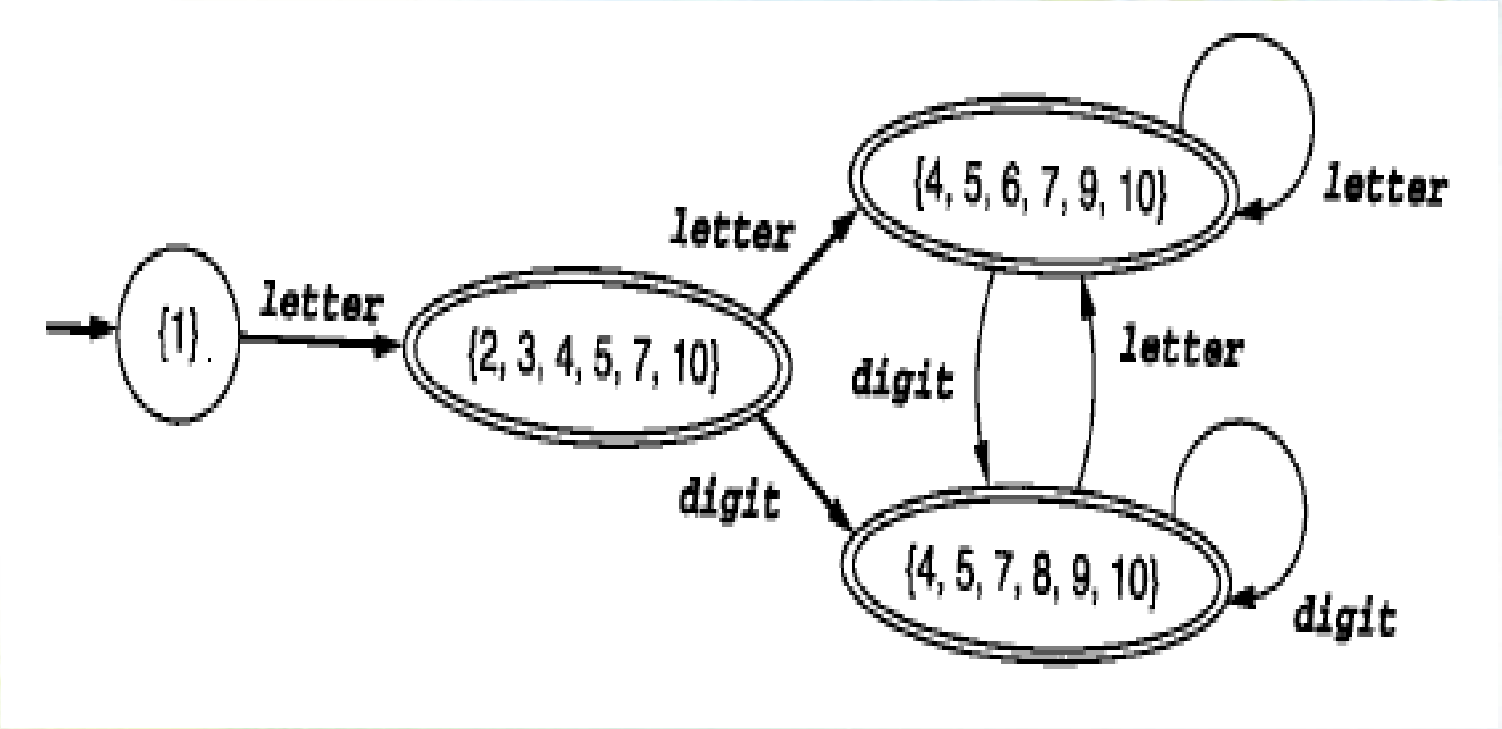

- 缺点：逐个找状态进行等价判断以确定是否进行合并，这样比较次数太多。

如何最小化——方法二

- 状态数最少

  →反向思考

  →从DFA拥有的最少状态（终态和非终态）开始进行分析

  →根据目标是否一致来确定是否需要分析

首先，令

A= { 1 }

B= { 2, 3, 4, 5, 7, 10 }

C= { 6, 9, 4, 7, 10, 5 }

D= { 8, 9, 4, 7, 5, 10 }

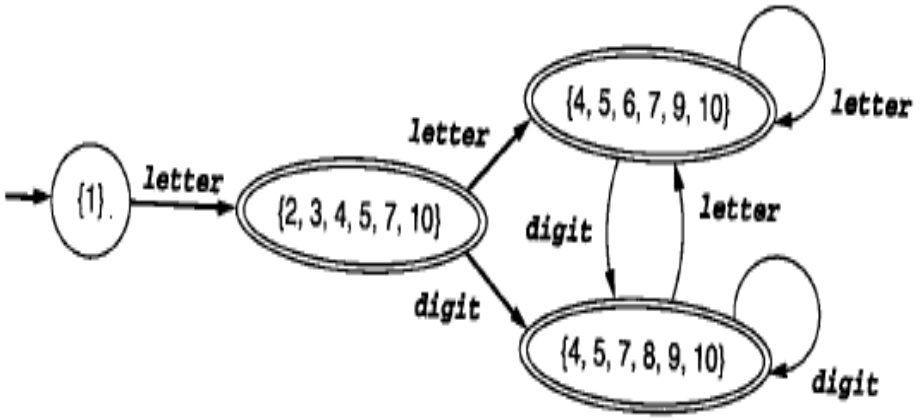

（1）将DFA中的状态划分为非终态集合s1={A}，和终态集合s2={B, C, D }

符号 / 状态集合	letter	digit
A	{ B }⊂S2	
B	{ C }⊂S2	{ D }⊂S2
C	{ C }⊂S2	{ D }⊂S2
D	{ C }⊂S2	{ D }⊂S2

(2)由于s1, s2集合中的各状态经符号letter和digit转换，得到的集合均属于同一集合。

- 最小状态DFA为：

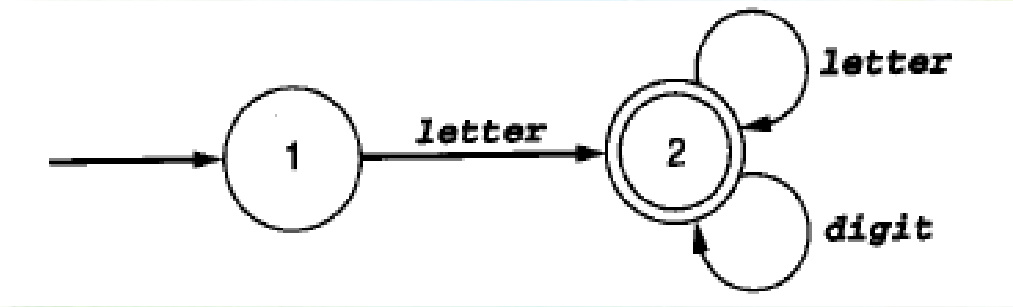

- 例2.19 将下面与正则表达式(a|ε)b*对应的DFA进行最小化
-

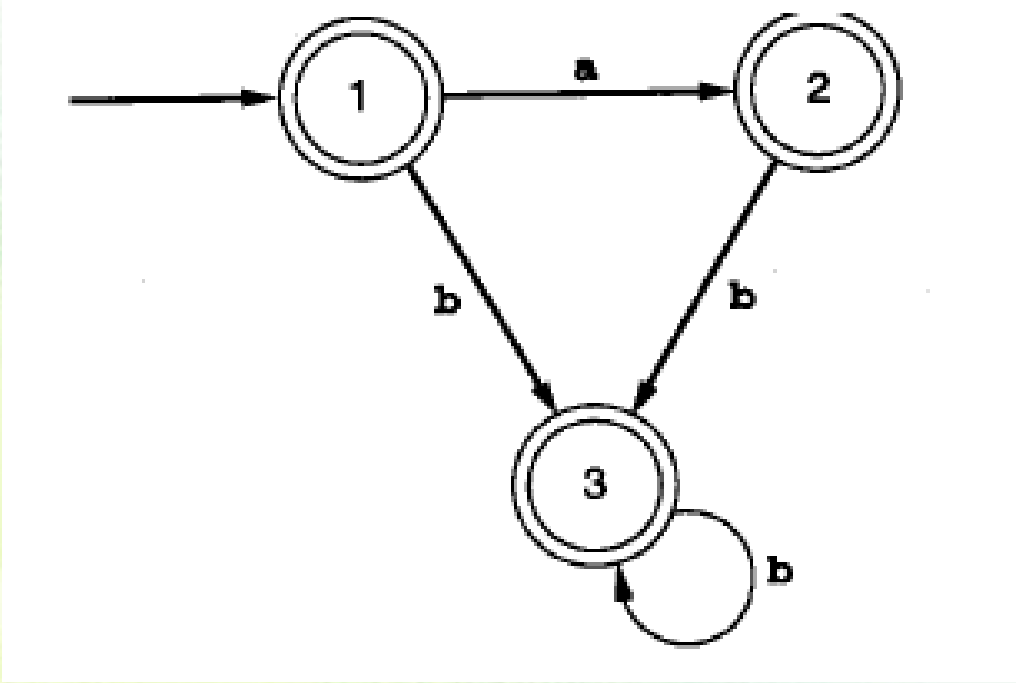

（1）将DFA中的状态划分为终态集合s1={1,2,3}，和非终态集合s2={ }

符号 / 状态集合	a	b
{1}	{ 2 }⊂S1	{3} ⊂S1
{2}		{3} ⊂S1
{3}		{3} ⊂S1

(2)可见{2}与{3}状态经a或b转换得到的状态集合是一样，但与{1}得到的状态集合不一样。因此{2}{3}合并作为一个状态处理。{1}则作为另一个状态。

因此，就得到了最小状态的DFA：

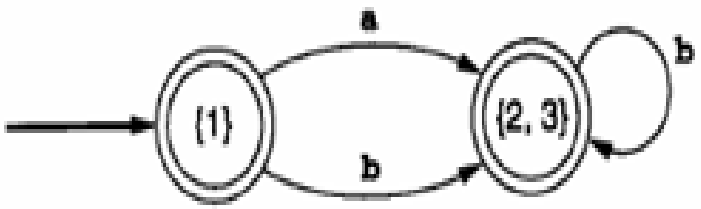

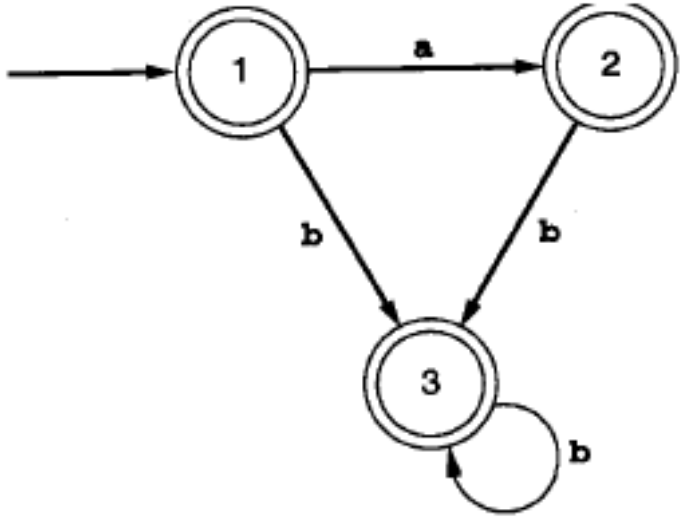

- 2.3.3 用代码实现有穷自动机

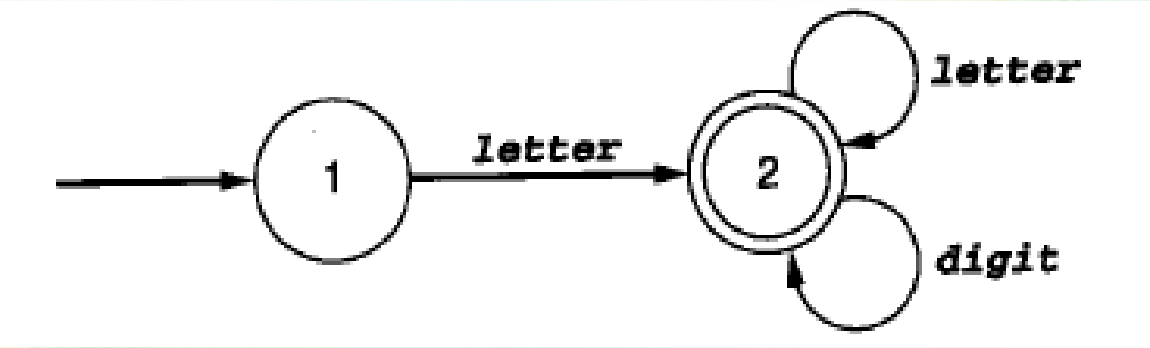

- 2.3.3 用代码实现有穷自动机

既然DFA可以反映单词串的识别过程，那么如何将DFA转换为程序代码？

- 首先让我们标识符中含了先行和最长子串原理的DFA图：

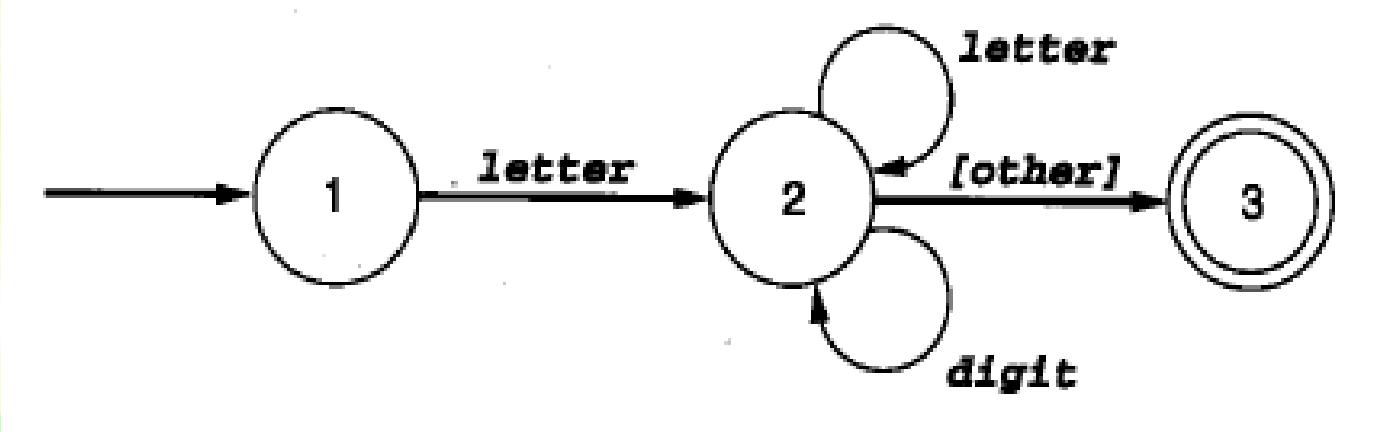

代码为：

```
{ starting in state 1 }
if the next character is a letter then
    advance the input;
    { now in state 2 }
   while the next character is a letter or a digit do
       advance the input; { stay in state 2 }
   end while;
   { go to state 3 without advancing the input }
   accept ;
else
    { error or other cases }
end if;
```

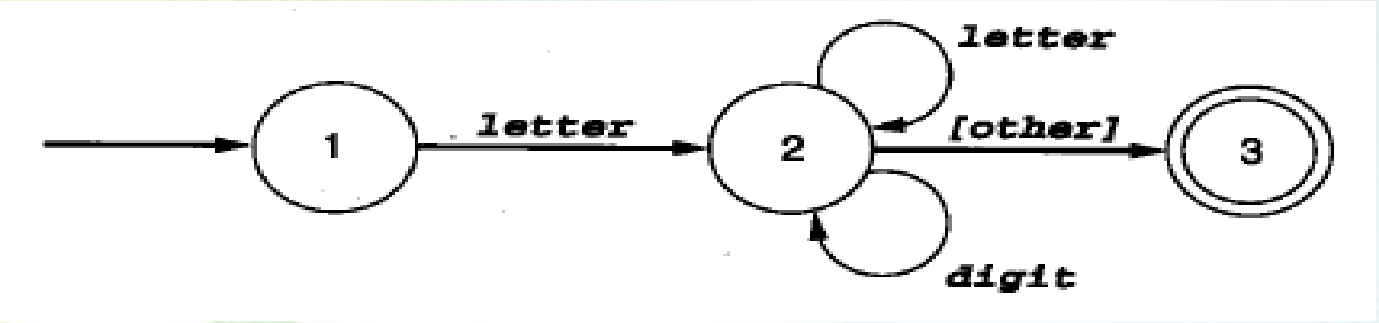

- 特点：状态少且DFA中的循环较小，那么就比较合适了。

- 缺点：
- 首先它是特殊的，即必须用略微不同的方法处理各个DFA，而且规定一个用这种办法将每个DFA翻译为代码的算法较难。

- 其次：当状态增多或更明确时，且当相异的状态与任意路径增多时，代码会变得非常复杂。

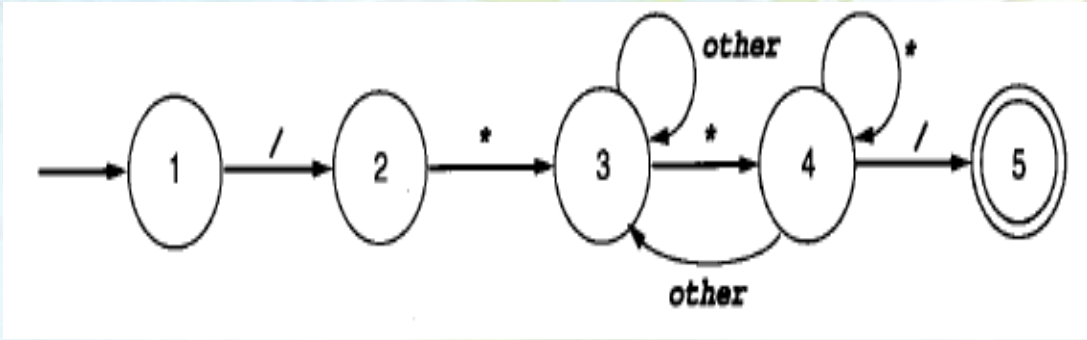


```
{ state 1 }
if the next character is " / " then
    advance the input: { state 2 }
  if the next character is "*" then
    advance the input; { state 3 }
    done := false;
    while not done do
      while the next input character is not "*" do
          advance the input;    { stay in state 3 }
      end while;
      advance the input; { state 4 }
      while the next input character is "*" do
          advance the input;     { stay in state 4 }
      end while;
      if the next input character is " / " then
          done : = true ;
      end if;
      advance the input;
    end while;
    accept; { state 5 }
  else
    { other processing }
  end if;
else
  { other processing }
end if;
```

较好的解决方法1

- ——状态转换方法
- 即利用一个变量保持当前的状态，并将转换写成一个双层嵌套的case语句而不是一个循环。
- 其中第1个case语句测试当前的状态，嵌套着的第2层测试输入字符及所给状态。

- 新代码：

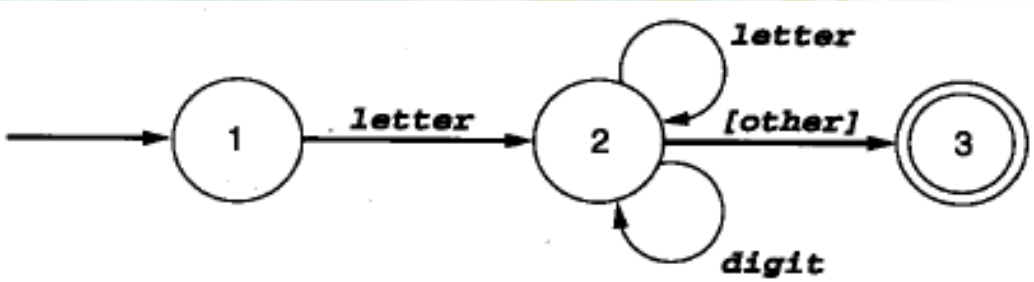


```
state := 1; { start }
while state = 1 or 2 do
  case state of
  1:  case input character of
      letter : advance the input;
               state := 2;
      else state := . . . { error or other };
      end case;
  2:  case input character of
      letter, digit: advance the input;
                     state := 2; { actually unnecessary }
      else state := 3;
      end case;
  end case;
end while;
if state = 3 then accept else error ;
```

```
state := 1; { start }
while state = 1, 2, 3 or 4 do
   case state of
   1:   case input character of
        "/" : advance the input;
              state := 2;
        else state := . . . { error or other };
        end case;
   2:   case input character of
        "*": advance the input;
              state := 3;
        else state := . . . { error or other };
        end case;
   3:   case input character of
        "*": advance the input;
              state := 4;
        else advance the input { and stay in state 3 };
        end case;
   4:   case input character of
        "/" advance the input;
              state := 5;
        "*": advance the input; { and stay in state 4 }
        else advance the input;
              state := 3;
        end case;
  end case;
end while;
if state = 5 then accept else error ;
```

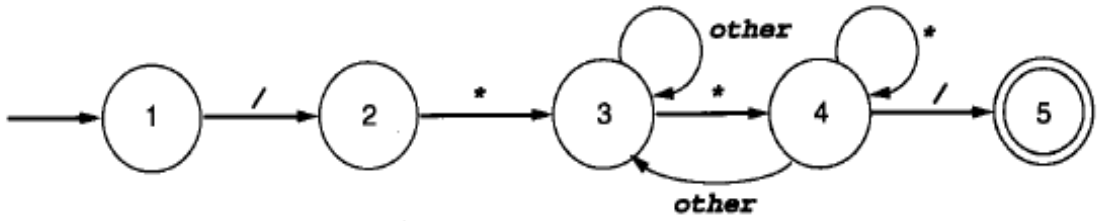

解决方法2

- 转换表(transition table)——二维数组
- 通过表示转换函数T值的状态和输入字符来索引

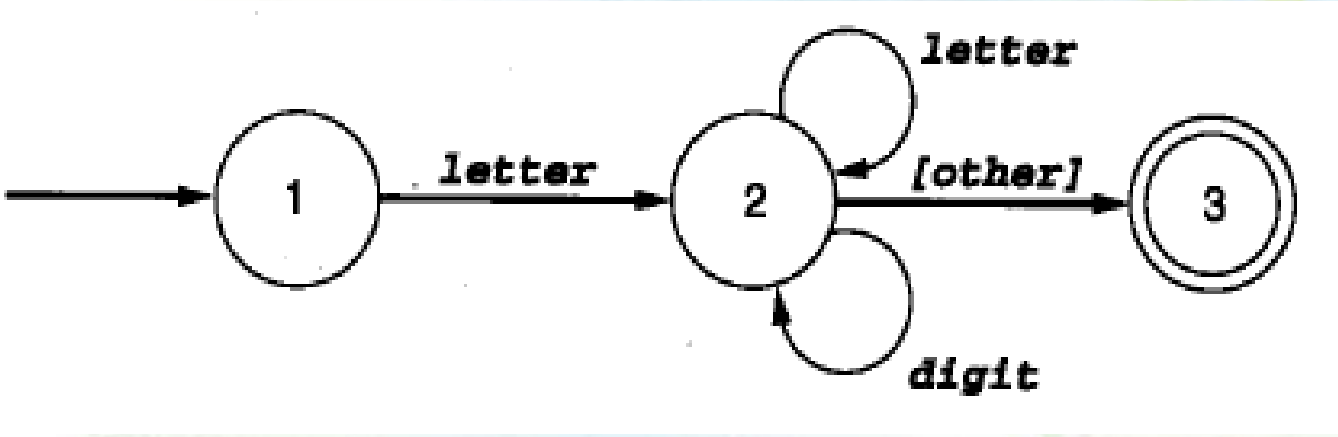

	字母表C中的字符
状态S	经转换T(S,c)所达到的状态

例如：标识符的DFA可表示为如下的转换表：

状态 \ 输入	字母	数字	其他
1	2		
2	2	2	3
3			